

مجموعه‌ای مرادی

۱- الف) درست

در این الگوریتم برای ساده‌شدن، تمام Feature ها را مستقل در نظر می‌گیرد

ب) درست

با انجام smoothing احتمال و قاعده‌ای که در داده تست صفر بوده، از صفر بزرگتر

می‌شود و دیگر overfitting نخواهد داشت

ج) نادرست

یکی از قدرت‌های درخت تصمیم این است که می‌تواند با انعطاف بالا مسائل مختلف

را مدل کند تا حدی که امکان overfitting دارد

د) درست

حق بیشتر یعنی دانستن جزئیات بیشتر از داده تست که این احتمال overfit

را بالا می‌برد

ه) درست

$IG(x) = H(y) - H(y|x)$ هر چه قدر مقادیر زیاد شود $H(y|x)$ کمتر می‌شود و $IG(x)$ بالا می‌رود

Subject: _____

Date _____

(نادرست)

درخت تصمیم می تواند ریزترین جزئیات یک مسئله را بیرون بکشد و ذاتا غیر خطی است

(نادرست)

مدل وقتی معروض train و validation به عمل کند under fitting رخ داده

(نادرست)

اگر پارامترها از داده Validation (Held-out) تنظیم می شود

۲- الف) بهترین ویژگی، بالاترین $IG(x)$ را دارد که این پایین ترین $H(Y|x)$.

$$H(Y|X_1) = - \sum_x P(x) \sum_y P(Y|x) \log_p P(Y|x)$$

$$= - \left(\frac{4}{10} \left(\frac{3}{4} \log \frac{3}{4} + \frac{1}{4} \log \frac{1}{4} \right) + \frac{6}{10} \left(\frac{4}{6} \log \frac{4}{6} + \frac{2}{6} \log \frac{2}{6} \right) \right)$$

$$= (0.4 \times 0.911 + 0.6 \times 0.911) = 0.911$$

$$H(Y|X_2) = - \left(\frac{3}{10} \left(1 \log 1 + 0 \log 0 \right) + \frac{7}{10} \left(\frac{4}{7} \log \frac{4}{7} + \frac{3}{7} \log \frac{3}{7} \right) \right)$$

$$= (0.3 \times 0 + 0.7 \times 0.915) = 0.641$$

$$H(Y|X_3) = - \left(\frac{4}{10} \left(\frac{3}{4} \log \frac{3}{4} + \frac{1}{4} \log \frac{1}{4} \right) + \frac{6}{10} \left(\frac{4}{6} \log \frac{4}{6} + \frac{2}{6} \log \frac{2}{6} \right) \right)$$

$$= (0.4 \times 0.911 + 0.6 \times 0.911) = 0.911$$

پس بهترین ویژگی جهت انتخاب X_2 است

ب) وقتی محقق درخت را تا به برگ ها pure می شوند، اما خاص جزئیات

مکان در باره داده تست را به مدل آموزش می دهد که منجر به overfitting

می شود که اینگونه درصدا زیاد داده جدید به دلیل عدم generalization، بدعمل می کند

$$\text{Gini Impurity} = 1 - \sum (P_i)^2$$

ج

$$G(X_1) = \left(\frac{5}{10} \left(1 - \left(\frac{1}{4} \right)^2 - \left(\frac{3}{4} \right)^2 \right) + \frac{5}{10} \left(1 - \left(\frac{2}{6} \right)^2 - \left(\frac{4}{6} \right)^2 \right) \right)$$

$$= 0.5 \times 0.375 + 0.5 \times 0.444 = 0.416$$

$$G(X_2) = \left(\frac{3}{10} \times 0 + \frac{7}{10} \left(1 - \left(\frac{3}{7} \right)^2 - \left(\frac{4}{7} \right)^2 \right) \right)$$

$$= 0.7 \times 0.419 = 0.292$$

$$G(X_3) = \left(\frac{4}{10} \left(1 - \left(\frac{1}{4} \right)^2 - \left(\frac{3}{4} \right)^2 \right) + \frac{6}{10} \left(1 - \left(\frac{2}{6} \right)^2 - \left(\frac{4}{6} \right)^2 \right) \right)$$

$$= 0.4 \times 0.375 + 0.6 \times 0.444 = 0.416$$

کمترین ناخالصی را X_2 داشت پس برای انشعاب انتخاب می شود

Subject:

Date:

$$P(Y = \text{spam} | W_1 = \text{best}, W_2 = \text{price})$$

(الف - 3)

$$= \underbrace{P(Y = \text{spam})}_P \times \frac{1}{1} \times \frac{1}{5} = \frac{P}{5}$$

$$P(Y = \text{ham} | W_1 = \text{best}, W_2 = \text{price})$$

$$= (1-P) \times \frac{1}{1} \times \frac{1}{4} = \frac{1-P}{4}$$

$$\Rightarrow \frac{P}{5} > \frac{1-P}{4} \Rightarrow 4P > 5 - 5P \Rightarrow P > \frac{5}{9}$$

$$P(W = \text{just} | Y = \text{spam}) = \frac{Y}{10} \rightarrow \text{just} \text{ (تعداد 10)}$$


تعداد 10 (تعداد 10)

$$P(W = \text{call} | Y = \text{ham}) = \frac{1}{1}$$

$$P(W = \text{offer} | Y = \text{ham}) = \frac{0}{1} = 0$$

$$P(Y = \text{spam}) = \frac{Y}{2}$$

DAT

$$(a) - 1^c$$


$$g \text{ a-Rel}V(a-b) = \min(a, b)$$


$$\Rightarrow x_i - \text{ReLU}(x_i - x_j^{\alpha_j}) = \min(x_i, x_j^{\alpha_j})$$

در دایره آخر داریم:

DAT

Subject:

Date:



$$\frac{\partial g}{\partial v_f} = 1 \times \left(-\frac{1}{(v_f)^2}\right) = -\left(\frac{1+e}{e}\right)^2 = A$$

$$\frac{\partial g}{\partial v_a} = \frac{\partial g}{\partial v_f} \cdot \frac{\partial v_f}{\partial v_a} = A \times 1 = A$$

$$\frac{\partial g}{\partial v_f} = \frac{\partial g}{\partial v_a} \cdot \frac{\partial v_a}{\partial v_f} = A \times e^{v_f} = \frac{A}{e}$$

$$\frac{\partial g}{\partial v_r} = \frac{\partial g}{\partial v_f} \cdot \frac{\partial v_f}{\partial v_r} = \frac{A}{e} \times (-1) = -\frac{A}{e}$$

$$\frac{\partial g}{\partial v_r} = \frac{\partial g}{\partial v_f} \cdot \frac{\partial v_f}{\partial v_r} = \left(-\frac{A}{e}\right) \times 1 = -\frac{A}{e}$$

$$\frac{\partial g}{\partial v_r} = \frac{\partial g}{\partial v_f} \cdot \frac{\partial v_f}{\partial v_r} = \left(-\frac{A}{e}\right) \times 1 = -\frac{A}{e}$$

$$\frac{\partial g}{\partial v_0} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial v_0} = \left(-\frac{A}{e}\right) \times 1 = -\frac{A}{e}$$

$$\frac{\partial g}{\partial w_x} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial w_x} = \left(-\frac{A}{e}\right) \times 1 = -\frac{A}{e}$$

$$\frac{\partial g}{\partial w_1} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial w_1} = \left(-\frac{A}{e}\right) \times (-\gamma) = \frac{\gamma A}{e} \quad \frac{\partial g}{\partial x_1} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial x_1} = \left(-\frac{A}{e}\right) \times (-\gamma) = \frac{\gamma A}{e}$$

$$\frac{\partial g}{\partial w_0} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial w_0} = \left(-\frac{A}{e}\right) \times (-1) = \frac{A}{e} \quad \frac{\partial g}{\partial x_0} = \frac{\partial g}{\partial v_r} \cdot \frac{\partial v_r}{\partial x_0} = \left(-\frac{A}{e}\right) \times (1) = -\frac{\gamma A}{e}$$

DAT

Subject:

Date:

classification مسائل برای SSE از Binary cross entropy (الف)

به دلیل صواب بودن بهتر است و در local minima گیر نمی افتد

$$J(w) = \sum_{i=1}^n [-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)})] \quad (ب)$$

مبنای $\log$ را e می گیریم

$$\frac{\partial J}{\partial \hat{y}^{(i)}} = \sum_{i=1}^n -\frac{y^{(i)}}{\hat{y}^{(i)}} + \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} = \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1-\hat{y}^{(i)})} \quad (I)$$

$$\hat{y}^{(i)} = \sigma(z) \Rightarrow \frac{\partial \hat{y}^{(i)}}{\partial z} = -\frac{e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2} \quad (II)$$

$$z = w^T x^{(i)} \Rightarrow \frac{\partial z}{\partial w} = x^{(i)} \quad (III)$$

$$\begin{aligned} (I) \times (II) \times (III) &\Rightarrow \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1-\hat{y}^{(i)})} \times \frac{e^{-z}}{(1+e^{-z})^2} \times x^{(i)} \\ &= \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1-\hat{y}^{(i)})} \times \frac{\hat{y}^{(i)}}{\hat{y}^{(i)}(1-\hat{y}^{(i)})} \times x^{(i)} = (\hat{y}^{(i)} - y^{(i)}) x^{(i)} \end{aligned}$$

$$\frac{\partial J}{\partial w} = \sum_{i=1}^n (\sigma(w^T x^{(i)}) - y^{(i)}) x^{(i)}$$

$$w^{(i)} - w^{(i)} - \alpha \nabla_w J = w$$

$$\Rightarrow w^{(i)} = w^{(i)} - \alpha (\sigma(w^T x^{(i)}) - y^{(i)}) x^{(i)}$$

DAT

Subject:

Date:

نکته: multi-class نمودار تابع softmax به جای sigmoid استفاده می‌کنیم

$$\text{softmax} \Rightarrow \hat{y}^{(i)} = \frac{e^{w_j^{(i)} \cdot x^{(i)}}}{\sum_{j=1}^K e^{w_j^{(i)} \cdot x^{(i)}}}$$

$$J(w) = \sum_{i=1}^n \sum_{j=1}^K y_j^{(i)} \log(\hat{y}_j^{(i)})$$

برای تابع loss می‌داریم:

DAT

$$W = W + \eta y X \quad \leftarrow y \neq \hat{y} \quad \text{الف) اگر}$$

$$W^T X_A = [0 \ 0 \ 0] \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = 0 \quad \text{sign}(0) = +1 \Rightarrow y = \hat{y} \quad \checkmark$$

$$W^T X_B = [0 \ 0 \ 0] \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = 0 \quad \text{sign}(0) = +1 \Rightarrow y = \hat{y} \quad \checkmark$$

$$W^T X_C = [0 \ 0 \ 0] \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} = 0 \quad \text{sign}(0) = +1 \Rightarrow y \neq \hat{y} \Rightarrow W = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}$$

$$W^T X_D = [-1 \ -1 \ 2] \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} = -1 \quad \text{sign}(-1) = -1 \Rightarrow y = \hat{y} \quad \checkmark$$

$$W = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix} \quad \text{بردار وزن آپدیت شده:}$$

$$W^T X_A = [-1 \ -1 \ 2] \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = -1 \quad \text{sign}(-1) = -1 \Rightarrow y \neq \hat{y} \quad \text{ب)}$$

$$W^T X_B = [-1 \ -1 \ 2] \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = 4 \quad \text{sign}(4) = +1 \Rightarrow y = \hat{y} \quad \checkmark$$

در الف بررسی شد و درست
پیش بینی شد

با اینکه در یک مرحله نتوانستیم تمام داده‌ها را درست دسته‌بندی کنیم ولی به این معنا نیست

که خطی جدایی پذیر نیستند. در واقع بعد از اجرای یک مرحله دیگر به وزن $\begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix}$

ما رسیدیم که تمام داده‌ها را درست دسته‌بندی می‌کنند

بج در ب گفته شد که با وزن $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ داده ها خطی برای پذیر هستند پس

با استفاده از این وزن یک مرز تعیین می کنیم

$$\Rightarrow 0 \times f_0 + 1 \times f_1 + 3 \times f_2 = f_1 + 3f_2 = 0$$

معادله $f_1 + 3f_2 = 0$ یک مرز تصمیم است

$$A: 2 + 3 > 0 \quad \checkmark$$

$$B: -1 + 6 > 0 \quad \checkmark$$

$$C: 1 - 2 < 0 \quad \checkmark$$

$$D: -2 - 3 < 0 \quad \checkmark$$

✓ الف) برای توابع محدب: $\theta < 1$ $f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$

• $f(x) = \sqrt{x} \Rightarrow \sqrt{\theta x + (1-\theta)y} \stackrel{?}{\leq} \theta \sqrt{x} + (1-\theta)\sqrt{y}$

$\xrightarrow{(\cdot)^2} \theta x + (1-\theta)y \stackrel{?}{\leq} \theta^2 x + (1-\theta)^2 y + 2\theta(1-\theta)\sqrt{xy}$

$\Rightarrow \theta(1-\theta)x + \theta(1-\theta)y \stackrel{?}{\leq} 2\theta(1-\theta)\sqrt{xy}$

$\xrightarrow{\div \theta(1-\theta)} \frac{x+y}{2} \stackrel{?}{\leq} 2\sqrt{xy}$

اما می دانیم که میانگین حسابی دو عدد از میانگین هندسی دو عدد بزرگتر است

$\Rightarrow x^2 + y^2 + 2xy \stackrel{?}{\leq} 4xy \Rightarrow (x-y)^2 \leq 0$ ✗

پس $f(x) = \sqrt{x}$ محدب نیست

• $f(x) = x^2 \Rightarrow (\theta x + (1-\theta)y)^2 \stackrel{?}{\leq} \theta x^2 + (1-\theta)y^2$

$\Rightarrow \theta^2 x^2 + (1-\theta)^2 y^2 + 2\theta(1-\theta)xy \stackrel{?}{\leq} \theta x^2 + (1-\theta)y^2$

$\Rightarrow \theta(1-\theta)x^2 + \theta(1-\theta)y^2 - 2\theta(1-\theta)xy \stackrel{?}{\geq} 0$

DAT

$\Rightarrow \theta(1-\theta)(x-y)^2 \geq 0$ ✓ $\theta > 0$ $1-\theta > 0$ $(x-y)^2 \geq 0 \Rightarrow f(x) = x^2$ محدب است

Subject:

Date:

$$f(x) = -\log(x) \quad 0 < x$$

(-)

$$f'(x) = -\frac{1}{x} \Rightarrow f''(x) = \frac{1}{x^2}$$

$f''(x)$ در بازه $(0, \infty)$ مثبت است پس $f(x)$ محدب است

$$f(x) = x^4 - 2x^2 \quad x \in \mathbb{R}$$

$$f'(x) = 4x^3 - 4x \Rightarrow f''(x) = 12x^2 - 4$$

$f''(x)$ به ازای $x=0$ منفی است پس $f(x)$ محدب نیست

DAT

Subject:

Date:

1- الف) K و X مربعی هستند پس بُعد ماتریس خروجی:

طول و عرض برابر $\uparrow$

$$\frac{W/H - F_{W/H} + P}{S_{W/H}} + 1 = \frac{5 - 2 + 2}{1} + 1 = 5$$

$$X = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 2 & 0 & 1 & 0 \\ 0 & 3 & 1 & 2 & 1 & 0 \\ 0 & 0 & 1 & 3 & 1 & 0 \\ 0 & 2 & 3 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}_{6 \times 6}$$

$\leftarrow$ padding X

$$K = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$$

برای درایه اول ماتریس خروجی محاسبات را از عناصر دهم باقی داردها

به طور مشابه محاسبات شوند

$$\begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} * \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} = 0 \times 1 + 0 \times (-1) + 0 \times 0 + 1 \times 1 = 1$$

$$O = \begin{bmatrix} 1 & 2 & 0 & 1 & 0 \\ 2 & 0 & 4 & 0 & 1 \\ -3 & 3 & 2 & 2 & 1 \\ 2 & 2 & -1 & 4 & 1 \\ -2 & -1 & 2 & -1 & 2 \end{bmatrix}_{5 \times 5}$$

DAT

ب) i - attention score محاسبه و ضرب Q و K ها ($q_i \cdot k_j$) به صورت

ماتریس QK^T

$$QK^T = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix}$$

$$\xrightarrow{\text{scale}} \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix} = S$$

$$\text{softmax}(S) \Rightarrow \begin{bmatrix} 0.11 & 0.34 \\ 0.15 & 0.15 \end{bmatrix} \quad \text{- ii}$$

$$\xrightarrow{\div \text{sum}} \begin{bmatrix} \frac{0.11}{0.46} & \frac{0.34}{0.49} \\ 0.15 & 0.15 \end{bmatrix} = \begin{bmatrix} 0.239 & 0.694 \\ 0.15 & 0.15 \end{bmatrix} = S'$$

$$O = S'V \Rightarrow O = \begin{bmatrix} 0.239 & 0.694 \\ 0.15 & 0.15 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1.33 & 2.34 \\ 1.15 & 0.6 \end{bmatrix} \quad \text{- iii}$$