



هوش مصنوعی

بهار ۱۴۰۵

استاد: ماری اوریاد
گردآورندگان: رادین جریره، فاطمه جعفرزاده،
معین حسینی، آریانا زال‌نژاد، علی نوری

مهلت ارسال: ۳۰ خرداد

یادگیری ماشین

تمرین چهارم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- در طول ترم امکان ارسال با تاخیر پاسخ همه‌ی تمارین تا سقف ۴ روز و در مجموع ۱۰ روز، وجود دارد. پس از گذشت این مدت، پاسخ‌های ارسال‌شده پذیرفته نخواهند بود. همچنین، به ازای هر ساعت تأخیر غیر مجاز ۰.۵ درصد از نمره تمرین به صورت ساعتی کسر خواهد شد.
- هم‌کاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتماً باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفاً تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.
- پاسخنامه سوالات را در سامانه کوئرا و به فرمت `AI_HW4_<STUDENT_ID>` بارگزاری کنید.
- نمره امتیازی بخش تئوری این تمرین تنها روی بخش تئوری همین تمرین اعمال شده و بر روی باقی بخش‌های درس **سرریز ندارد**.

سوالات نظری (۱۰۰+۱۰ نمره)

۱. (۱۶ نمره) با ذکر دلیل، درست و غلط بودن گزاره‌های زیر را مشخص نمایید.
 - (آ) در الگوریتم Naive Bayes فرض می‌شود که ویژگی‌های مسئله (Attributes یا Features) نسبت به یک دیگر مستقل هستند.
 - (ب) هدف اصلی از Smoothing در Naive Bayes جلوگیری از صفر شدن احتمال Posterior و وقوع Overfitting است.
 - (ج) درخت تصمیم تنها برای مسائل دسته‌بندی (Classification) قابل استفاده است.
 - (د) به طور کلی هر چه عمق درخت تصمیم بیشتر باشد، احتمال Overfitting بیشتر است.
 - (ه) اگر یک ویژگی تعداد بسیار زیادی مقدار یکتا داشته باشد، معیار Information Gain تمایل به انتخاب آن دارد.
 - (و) درخت تصمیم نمی‌تواند روابط غیرخطی بین ویژگی‌ها را مدل کند.
 - (ز) اگر عملکرد مدل روی دادگان Train و Validation ضعیف باشد، مشکل غالباً Underfitting است.
 - (ح) برای یافتن مقادیر مناسب ابرپارامترها (Hyper-parameters) از مجموعه دادگان آموزش استفاده می‌شود.
۲. (۱۳ نمره) شما به عنوان یک مهندس یادگیری ماشین در یک شرکت فناوری، مسئول طراحی یک سیستم تشخیص ایمیل‌های اسپم هستید. داده‌های آموزشی شما شامل ۱۰ ایمیل با ویژگی‌های زیر است:
 - X_1 : آیا فرستنده در لیست مخاطبین است؟ (۱: بله، ۰: خیر)
 - X_2 : آیا ایمیل حاوی لینک‌های مشکوک است؟ (۱: بله، ۰: خیر)

Class	X_3	X_2	X_1	ID
۰	۱	۱	۰	۱
۱	۰	۱	۱	۲
۰	۰	۰	۱	۳
۱	۱	۱	۱	۴
۱	۱	۱	۰	۵
۰	۱	۰	۱	۶
۰	۰	۱	۰	۷
۰	۱	۱	۰	۸
۰	۱	۰	۱	۹
۰	۰	۱	۱	۱۰

- X_3 : آیا در متن ایمیل از کلمات پرخاشگرانه استفاده شده است؟ (۱: بله، ۰: خیر)
- کلاس: ایمیل اسپم است (۱) یا خیر (۰).

(آ) محاسبات لازم برای انتخاب بهترین ویژگی جهت انشعاب در گره ریشه را انجام دهید.

(ب) تیم مدیریت شرکت اصرار دارد که مدل باید دقت ۱۰۰٪ روی داده‌های آموزشی داشته باشد، بنابراین پیشنهاد می‌دهند درخت را تا جایی رشد دهیم که تمامی گره‌های برگ Pure شوند. آیا در این صورت مدل لزوماً برای داده‌های تست بهتر عمل می‌کند؟ پاسخ خود را با ذکر دلیل توضیح دهید.

(ج) علاوه بر معیار Information Gain، یک معیار دیگر برای انتخاب فیچر در درخت تصمیم به نام Gini Impurity داریم. در مورد چگونگی استفاده از این معیار برای انتخاب ویژگی انشعاب درخت تحقیق کنید و مجدداً محاسبات لازم برای انتخاب بهترین ویژگی جهت انشعاب در گره ریشه را با استفاده از این معیار انجام دهید.

۳. (۱۵ نمره) فرض کنید هر ایمیل شامل K کلمه به صورت $w_1, \dots, w_K$ و یک برچسب دودویی Y است که مقدار spam یا ham می‌گیرد. قاعده تصمیم‌گیری در مدل Naïve Bayes که از فرض Bag-of-Words بودن ایمیل استفاده می‌کند به صورت زیر خواهد بود:

$$\arg \max_y P(Y = y \mid w_1, \dots, w_K) = \arg \max_y P(Y = y) \prod_{i=1}^K P(W = w_i \mid Y = y)$$

(آ) فرض کنید مدل خود را بر روی مجموعه بزرگی از ایمیل‌ها آموزش داده‌اید و به احتمالات زیر رسیده‌اید:

W	best	today	price
$P(W \mid Y = \text{spam})$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$
$P(W \mid Y = \text{ham})$	$\frac{1}{12}$	$\frac{1}{3}$	$\frac{1}{6}$

ایمیل "best price" به شما داده می‌شود. احتمال $P(Y = \text{spam})$ در توزیع پیشین $P(Y)$ باید از چه مقداری بزرگتر باشد تا این ایمیل به عنوان spam طبقه‌بندی شود؟

(ب) حالا فرض کنید که می‌خواهید مدل جدیدی را آموزش بدهید و امکان استفاده از مدل بخش قبل را ندارید. پنج ایمیل زیر به عنوان داده‌ی آموزشی در اختیار شما قرار گرفته است:

- special offer just today (Spam)
- summer season off just for you (Spam)
- meeting today (Ham)

- call me later (Ham)
- see you tomorrow (Ham)

بدون استفاده از smoothing، مقادیر زیر را محاسبه کنید:

- $P(W = \text{just} \mid Y = \text{spam})$
- $P(W = \text{call} \mid Y = \text{ham})$
- $P(W = \text{offer} \mid Y = \text{ham})$
- $P(Y = \text{spam})$

۴. (۱۸ نمره)

(آ) یک شبکه عصبی با حداکثر ۳ لایه مخفی طراحی کنید که خروجی آن برابر با تابع زیر باشد:

$$f(x_1, x_2, x_3) = \min(x_1, x_2^{x_3}).$$

توجه کنید که تنها ورودی‌های مجاز x_1, x_2, x_3 هستند و امکان افزودن ورودی کمکی به شبکه طراحی شده وجود ندارد. تابع فعال‌سازی هر نورون تنها روی ترکیب خطی ورودی‌های همان نورون اعمال می‌شود. برای توابع فعال‌سازی لایه‌های مخفی استفاده از تمامی توابع دلخواه مجاز است اما تابع فعال‌سازی لایه خروجی باید تابع همانی $f(x) = x$ باشد.


(ب) تابع زیر را در نظر بگیرید:

$$f(w, x) = \frac{1}{1 + e^{-(w \cdot x + w_1 x_1 + w_2 x_2)}}$$

گراف محاسبات متناظر با این تابع در شکل زیر آمده است. با فرض ورودی‌های زیر:

$$w_0 = 2, \quad x_0 = -1, \quad w_1 = -3, \quad x_1 = -2, \quad w_2 = -3$$

ابتدا forward pass را انجام دهید و مقادیر محاسبه شده در هر مرحله را بنویسید. سپس با استفاده از این مقادیر محاسبات backward pass را انجام داده و مشتق خروجی نهایی را نسبت به خروجی هر رأس حساب کنید.



۵. (۱۵ نمره)

برای آموزش یک مدل رگرسیون لجستیک از تابع loss زیر استفاده می‌شود.

$$J(w) = \sum_{i=1}^n [-y^{(i)} \log(\sigma(w^T x^{(i)})) - (1 - y^{(i)}) \log(1 - \sigma(w^T x^{(i)}))]$$

که در آن $\sigma(z) = \frac{1}{1+e^{-z}}$ ، و $y^{(i)} \in \{0, 1\}$ ، و $x^{(i)}$ بردار ویژگی نمونه i ام است.

- (آ) در مسائل طبقه‌بندی این تابع بیشتر ترجیح داده می‌شود یا تابع SSE loss که از مربع اختلاف برچسب‌های واقعی و مقدار پیش‌بینی شده توسط مدل به صورت $(y - \sigma(w^T x))^2$ استفاده می‌کند؟ چرا؟
- (ب) مشتق گرادیان $\nabla_w J(w)$ را نسبت به بردار وزن w محاسبه کنید.
- (ج) قاعده به‌روزرسانی گرادیان کاهشی تصادفی (SGD) را برای یک نمونه $(x^{(i)}, y^{(i)})$ بنویسید.
- (د) اگر به جای مسئله دسته‌بندی دو کلاسه با مسئله دسته‌بندی سه کلاسه روبرو بودیم، تابع loss و فرایند آموزش به چه شکل تغییر می‌کردند؟

۶. (۱۵ نمره) می‌خواهیم با استفاده از ویژگی‌های زیر پرسپترون برای تشخیص بیماری افراد آموزش دهیم. مدل پرسپترون به این صورت تعریف می‌شود:

$$\hat{y} = \text{sign}(w \cdot f + w_1 f_1 + w_2 f_2)$$

که در آن $f = 1$ بایاس ثابت و برچسب $y = +1$ نشان‌دهنده مبتلا بودن بیمار و $y = -1$ نشان‌دهنده سالم بودن او است. همچنین داده‌های آموزشی زیر را نیز در اختیار داریم:

بیمار	f_1 (قند)	f_2 (فشار)	y
A	۲	۱	+۱
B	-۱	۲	+۱
C	۱	-۲	-۱
D	-۲	-۱	-۱

بردار وزن اولیه را $(w, w_1, w_2) = (0, 0, 0)$ و نرخ یادگیری را $\eta = 1$ در نظر می‌گیریم. همچنین داده‌ها به ترتیب با شروع از A به الگوریتم داده می‌شوند.

- (آ) الگوریتم آموزش پرسپترون را یک مرحله روی تمامی داده‌ها اجرا کنید و در هر مرحله مقدار $\hat{y}$ و بردار وزن آپدیت شده را بنویسید.
- (ب) با وزن‌های به دست آمده در بخش (الف)، آیا تمام داده‌های آموزشی درست دسته‌بندی می‌شوند؟ اگر نه، آیا این لزوماً به معنای خطی جدا ناپذیر بودن داده‌هاست؟ توضیح دهید.
- (ج) نشان دهید داده‌ها خطی جداپذیر هستند یا نه. اگر بله، یک مرز تصمیم به صورت معادله ارائه دهید و نشان دهید که تمام نمونه‌ها را درست جدا می‌کند.

۷. (۸ نمره)

(آ) با استفاده از شرط نابرابری Jensen، محدب بودن یا نبودن توابع زیر را بر روی دامنه‌های داده شده بررسی کنید:

$$\bullet f(x) = \sqrt{x} \text{ بر روی } [0, \infty)$$

$$\bullet f(x) = x^2 \text{ بر روی مجموعه کل اعداد حقیقی}$$

(ب) با بررسی مشتق دوم، محدب بودن یا نبودن توابع زیر را بر روی دامنه‌های داده شده بررسی کنید:

$$\bullet f(x) = -\log(x) \text{ بر روی } (0, \infty)$$

• $f(x) = x^4 - 2x^2$ بر روی مجموعه کل اعداد حقیقی

۸. (۱۰ نمره) امتیازی.

(آ) یک نقشه‌ی ویژگی ورودی (Input Feature Map) و یک فیلتر (Kernel) به صورت زیر در اختیار داریم:

$$X = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 3 & 1 & 2 & 1 \\ 0 & 1 & 3 & 1 \\ 2 & 3 & 1 & 2 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$$

اطلاعات کانولوشن به شکل زیر هستند:

- اندازه‌ی فیلتر: 2×2
- مقدار padding: $p = 1$
- مقدار stride: $s = 1$
- بایاس: صفر

عملیات کانولوشن را به طور کامل انجام داده و نقشه‌ی ویژگی خروجی را به دست آورید.

(ب) فرض کنید یک دنباله‌ی ورودی متنی شامل دو توکن باشد. در یک لایه‌ی Attention از مدل ترنسفورمر، بردارهای Query، Key و Value برای این دو توکن به صورت زیر به دست آمده‌اند:

$$Q = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad K = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad V = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

که در آن:

- هر سطر متناظر با یک توکن است.
 - بُعد بردارهای Query و Key و Value برابر $d = 2$ است.
 - مکانیزم توجه از نوع Dot-Product است.
- ماتریس امتیازهای توجه (Attention Score) را محاسبه کنید.
 - امتیازهای نرمالایز شده‌ی توجه را با اعمال تابع softmax روی هر سطر از ماتریس امتیازها به دست آورید (استفاده از ماشین حساب مجاز است).
 - خروجی نهایی مکانیزم Attention را محاسبه کنید.