



هوش مصنوعی

بهار ۱۴۰۵

استاد: ماری اوریاد

گردآوردندگان: یاسمین رجبی، کیارش صانعی، امیرپارسا صفری،
علی منصوریان، آرش نظری منش، علی نوری

مهلت ارسال: ۱۵ تیر

یادگیری تقویتی

تمرین پنجم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- در طول ترم امکان ارسال با تاخیر پاسخ همه‌ی تمارین تا سقف ۴ روز و در مجموع ۱۰ روز، وجود دارد. پس از گذشت این مدت، پاسخ‌های ارسال شده پذیرفته نخواهند بود. همچنین، به ازای هر ساعت تأخیر غیر مجاز ۰.۵ درصد از نمره تمرین به صورت ساعتی کسر خواهد شد.
- هم‌کاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتماً باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفاً تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.
- پاسخنامه سوالات را در سامانه کوئرا و به فرمت `AI_HW5_<STUDENT_ID>` بارگزاری کنید.

سوالات نظری (۱۰۰ نمره)

۱. (۱۵ نمره) با ذکر دلیل، درست و غلط بودن گزاره‌های زیر را مشخص نمایید.
 - (آ) در الگوریتم Value Iteration، نرخ همگرایی به سیاست بهینه π^* معمولاً سریع‌تر از نرخ همگرایی خود تابع ارزش V^* است؛ به این معنا که ممکن است سیاست بهینه قبل از اینکه تابع ارزش به مقدار دقیق خود برسد، ثابت شود.
 - (ب) Q-learning تنها زمانی مقادیر بهینه Q-values را یاد می‌گیرد که کنش‌هایی (actions) که در نهایت انتخاب می‌شود، بر اساس سیاست (policy) بهینه باشد.
 - (ج) اگر بدانیم که $|A| \approx |S|$ آنگاه پیچیدگی زمانی اجرای هر ایتريشن در policy iteration و value iteration تقریباً با هم برابر می‌شود.
 - (د) در یک MDP با حالات محدود و پاداش با باند مشخص و $\gamma < 1$ ، در صورتی که همه پاداش‌ها با عدد ثابت c جمع شود، سیاست بهینه تغییر نمی‌کند.
 - (ه) اگر تنها تفاوت بین دو فرآیند تصمیم‌گیری مارکوف (MDP) مقدار ضریب تخفیف باشد، آنگاه این دو حتماً سیاست بهینه‌ی یکسانی دارند.
 - (و) در یک MDP با افق محدود (finite horizon) به طول T ، سیاست بهینه‌ی $\pi^*(s)$ ممکن است بسته به تعداد گام‌های باقی‌مانده تغییر کند؛ به این معنا که حتی برای یک حالت یکسان s نیز، سیاست بهینه می‌تواند ناپایستا (non-stationary) باشد.
- در مورد سوالات زیر توضیح مختصر و کوتاه دهید.

(آ) تفاوت on-policy RL و off-policy RL چیست؟

(ب) تفاوت model-based RL و model-free RL چیست؟

حل.

- (آ) **درست.** سیاست در هر گام از روی argmax کنش‌ها روی مقادیر Q به‌دست می‌آید، در حالی که V یک کمیت پیوسته است که با نرخ خطی (به ضریب γ) به مقدار دقیق V^* نزدیک می‌شود. برای آن‌که سیاست بهینه ثابت شود کافی است ترتیب کنش‌ها درست شود، نه مقدار دقیق آن‌ها؛ یعنی همین که فاصله‌ی V تا V^* از حد فاصله‌ی بین کنش بهینه و کنش‌های زیربهینه کوچک‌تر شود، argmax دیگر تغییر نمی‌کند. به همین دلیل معمولاً سیاست بهینه چند ایتريشن پیش از آن‌که V به‌طور کامل همگرا شود، تثبیت می‌گردد.
- (ب) **نادرست.** Q-learning یک الگوریتم off-policy است؛ به‌روزرسانی آن از جمله‌ی $\max_{a'} Q(s', a')$ استفاده می‌کند و نه از کنشی که واقعا انتخاب می‌شود. بنابراین کنش‌های اجراشده تنها نقش سیاست رفتاری (behavior policy) را دارند و لازم نیست بهینه باشند. تنها شرط همگرایی به Q^* این است که همه‌ی زوج‌های حالت-کنش بی‌نهایت بار دیده شوند (اکتشاف کافی) و شرایط نرخ یادگیری برقرار باشد. در واقع اگر عامل فقط کنش‌های بهینه را بزند، بعضی زوج‌ها هرگز دیده نمی‌شوند و همگرایی از بین می‌رود.
- (ج) **درست.** هزینه‌ی هر ایتريشن value iteration برابر $O(|S|^2|A|)$ است (برای هر حالت، روی هر کنش و روی همه‌ی حالت‌های بعدی جمع می‌زنیم). در policy iteration هر ایتريشن شامل دو بخش است: بهبود سیاست (policy improvement) با هزینه‌ی $O(|S|^2|A|)$ و ارزیابی سیاست (policy evaluation) که اگر به‌صورت دقیق و با حل دستگاه خطی انجام شود $O(|S|^3)$ است. حال اگر $|A| \approx |S|$ باشد، جمله‌ی $O(|S|^2|A|)$ به $O(|S|^3)$ تبدیل می‌شود و بنابراین هر دو الگوریتم در هر ایتريشن از مرتبه‌ی $O(|S|^3)$ خواهند بود؛ یعنی پیچیدگی زمانی هر ایتريشن‌شان هم‌مرتبه می‌شود.
- در صورتی که راه حلی بدون استفاده از روش حل دستگاهی خطی و با تحلیل اینکه به دلیل iterate کردن و مشخص نبودن زمان مورد نیاز برای همگرایی بررسی اردر زمانی ممکن نیست نوشته باشید نیز راه حل درست خواهد بود.
- (د) **نادرست.** در حالت کلی (افق محدود یا episodic) اگر به پاداش هر گام مقدار ثابت c اضافه شود، مجموع پاداش دریافتی هر سیاست به تعداد گام‌های طی‌شده بستگی دارد. اگر اپیزودها برای سیاست‌های مختلف طول‌های متفاوتی داشته باشند، مقدار اضافه‌شده دیگر برای همه‌ی سیاست‌ها یکسان نیست؛ بنابراین ممکن است ترتیب ارزش سیاست‌ها تغییر کند و در نتیجه سیاست بهینه نیز عوض شود. به عبارت دیگر، اگر یک سیاست اپیزود را در تعداد گام‌های کمتری به پایان برساند و سیاست دیگری مدت بیشتری ادامه یابد، جمع‌شدن مقدار ثابت c در هر گام می‌تواند یکی از این دو سیاست را نسبت به دیگری برتر کند. بنابراین افزودن یک ثابت به پاداش هر گام، لزوماً سیاست بهینه را حفظ نمی‌کند.
- (ه) **نادرست.** ضریب تخفیف تعیین می‌کند که عامل چه‌قدر به پاداش‌های آینده اهمیت دهد. با γ کوچک عامل کوتاه‌بین (myopic) می‌شود و پاداش آنی کوچک را ترجیح می‌دهد، و با γ بزرگ دوراندیش می‌شود و پاداش بزرگ باتاخير را انتخاب می‌کند. برای مثال در انتخاب میان «یک پاداش کوچک اکنون» و «یک پاداش بزرگ چند گام بعد»، مقدار γ می‌تواند کنش بهینه را عوض کند. پس تنها اختلاف در γ نمی‌تواند تضمین‌کننده‌ی یکسان‌بودن سیاست بهینه باشد.
- (و) **درست.** در افق محدود، ارزش و کنش بهینه به تعداد گام‌های باقی‌مانده (time-to-go) وابسته‌اند. با گام‌های زیاد باقی‌مانده ممکن است حرکتی دوراندیشانه بهینه باشد، در حالی که با گام‌های کم باقی‌مانده کنش دیگری که پاداش زود هنگام می‌دهد بهینه می‌شود. بنابراین سیاست بهینه در حالت کلی non-stationary است و به‌شکل $\pi_t^*(s)$ (وابسته به زمان) نوشته می‌شود؛ حتی برای یک حالت یکسان s نیز کنش بهینه می‌تواند در گام‌های مختلف فرق کند.

در ادامه به دو پرسش کوتاه پاسخ می‌دهیم:

- (آ) **تفاوت on-policy و off-policy:** در روش‌های on-policy، عامل ارزش همان سیاستی را یاد می‌گیرد که با آن رفتار می‌کند؛ یعنی سیاست رفتاری (behavior) و سیاست هدف (target) یکسان‌اند و به‌روزرسانی

از روی کنشی که واقعا انتخاب شده انجام می‌شود (مانند SARSA). در روش‌های off-policy، عامل ارزش سیاست هدفی را یاد می‌گیرد که با سیاست رفتاری تولیدکننده داده متفاوت است؛ برای مثال Q-learning با اینکه اکتشافی رفتار می‌کند، ارزش سیاست حریص/بهبوده را از راه $\max_{a'} Q(s', a')$ می‌آموزد. مزیت off-policy امکان استفاده مجدد از داده‌های سیاست‌های دیگر و یادگیری سیاست بهینه هم‌زمان با اکتشاف است.

(ب) **تفاوت model-based و model-free:** در model-based RL، عامل مدلی از محیط، یعنی تابع گذار $T(s' | s, a)$ و تابع پاداش $R(s, a, s')$ را می‌داند یا از روی تجربه تخمین می‌زند و سپس با برنامه‌ریزی روی این مدل (مثلا value/policy iteration) سیاست را به‌دست می‌آورد. در model-free RL، عامل بدون ساختن صریح T و R ، مستقیما توابع ارزش یا سیاست را از روی تجربه می‌آموزد (مانند Q-learning، TD و SARSA). روش‌های model-based معمولا از داده کارآمدتر استفاده می‌کنند اما به دقت مدل حساس‌اند، در حالی که روش‌های model-free ساده‌ترند ولی اغلب به داده‌ی بیشتری نیاز دارند.

۲. (۱۸ نمره) در شکل زیر یک محرک قرار دارد که همواره از خانه‌ی (۱، ۱) که با S نشان داده شده است، شروع به حرکت می‌کند. خانه‌ها را با زوج (سطر، ستون) نشان می‌دهیم. دو تا از خانه‌های جدول، خانه‌های پایانی هستند: خانه‌ی (۳، ۲) با جایزه‌ی $+10$ و خانه‌ی (۳، ۱) با جایزه‌ی -10 . در خانه‌هایی که پایانی نیستند، جایزه‌ای وجود ندارد. (جایزه‌ی یک خانه در صورتی دریافت می‌شود که محرک به آن خانه وارد شود). تابع احتمال حرکت به این صورت است که برای هر کنش (بالا، پایین، چپ یا راست) با احتمال 0.9 همان حرکت انجام می‌شود و با احتمال 0.05 (برای هر طرف) حرکتی عمود بر جهت در نظر گرفته‌شده رخ می‌دهد. اگر محرک با دیوار برخورد کند، در همان خانه‌ای که قرار داشته است باقی می‌ماند.

(۱، ۱)	(۱، ۲)	(۱، ۳)
S		-10
(۲، ۱)	(۲، ۲)	(۲، ۳)
		$+10$



(آ) فرض کنید محرک احتمال‌های مربوط به حرکت‌ها را می‌داند. دو مرحله‌ی اولیه‌ی الگوریتم Value Iteration را برای هر وضعیت (خانه) انجام دهید. $\gamma = 0.9$ و $V_i = 0$ را برای هر وضعیتی در نظر بگیرید.

(ب) با استفاده از $\alpha = 0.1$ و مقدارهای اولیه‌ی صفر، آپدیت‌های Temporal-Difference Learning را بعد از تجربه‌ی

$$(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$$

و

$$(1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow (2, 3)$$

برای $V(s)$ ها بنویسید ($\gamma = 0.9$). (توجه داشته باشید که در هر یک از مسیرهای گفته‌شده، کنش انتخاب‌شده‌ی محرک در هر گام «راست» بوده است؛ پس در مسیر دوم، رفتن از (۱، ۲) به (۲، ۲) نتیجه‌ی همان اشتباه‌شناسی در نتیجه حرکت است.)

(ج) همان‌طور که در بخش قبل گفته شد، کنش انتخاب‌شده در هر گام هر دو مسیر «راست» است. برای هر مسیر آپدیت‌های مقدار Q را با روش SARSA (در حالت on-policy) و با $Q_0(s, a) = 0$ و $\alpha = 0.1$ و $\gamma = 0.9$ محاسبه کنید.

(د) همان آپدیت‌ها را این بار با Q-learning (در حالت off-policy) دوباره حساب کنید و دو روش را مقایسه نمایید. گامی را که در آن این دو الگوریتم آپدیت متفاوتی تولید می‌کنند مشخص کنید و در یک جمله توضیح دهید چرا آن گام متفاوت بوده است.

(ه) با استفاده از همان دو مسیر بخش ۲ و $\gamma = 0.9$ ، برای هر حالتی که در این دو مسیر دیده شده است، تخمین ارزیابی مستقیم (Direct Evaluation) از $V^\pi(s)$ را با میانگین‌گیری از بازده‌های تخفیف‌خورده‌ی مشاهده‌شده از آن حالت به بعد محاسبه کنید. کدام حالت‌ها هنوز هیچ تخمینی ندارند؟ این موضوع چه ارتباطی به sample efficiency ارزیابی مستقیم در مقابل TD دارد؟

حل. پیش از حل، یادآوری می‌کنیم که پاداش هنگام وارد شدن به یک خانه دریافت می‌شود: ورود به (۱, ۳) پاداش ۱۰- و ورود به (۲, ۳) پاداش ۱۰+ می‌دهد و ورود به بقیه‌ی خانه‌ها پاداشی ندارد. دو خانه‌ی (۱, ۳) و (۲, ۳) پایانی‌اند و ارزش آن‌ها همواره صفر است (پاداش روی گذار ورود به آن‌ها لحاظ می‌شود). قرارداد جهت‌ها: «بالا» یعنی کاهش شماره‌ی سطر و «راست» یعنی افزایش شماره‌ی ستون؛ برخورد با دیوار عامل را در همان خانه نگه می‌دارد.

(آ) به‌روزرسانی Value Iteration به این صورت است:

$$V_{k+1}(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k(s')], \quad \gamma = 0.9.$$

ایتريشن اول (V_1): چون $V_1 \equiv 0$ است، هر جمله فقط پاداش آنی مورد انتظار می‌شود. تنها خانه‌هایی که می‌توانند در یک گام وارد یک خانه‌ی پایانی شوند مقدار غیرصفر می‌گیرند:

- در (۲, ۲) کنش «راست» با احتمال ۰/۹ وارد (۲, ۳) می‌شود: $V_1(2, 2) = 0.9 \times 10 = 9$.
- در (۱, ۲) بهترین کنش «چپ» است (پرهیز از (۱, ۳))، پس $V_1(1, 2) = 0$. کنش «راست» مقدار $-9 = (-10) \times 0.9$ می‌داد که بدترین است.
- خانه‌های (۱, ۱) و (۲, ۱) در یک گام به هیچ خانه‌ی پایانی نمی‌رسند: $V_1 = 0$.

ایتريشن دوم (V_2): اکنون با V_1 به‌دست‌آمده، برای هر خانه بهترین کنش را حساب می‌کنیم. نمونه‌ی محاسبات:

$$V_2(2, 2) = \underbrace{0.9 [10 + 0.9(0)]}_{(2,3) \rightarrow \text{راست}} + \underbrace{0.05 [0 + 0.9(0)]}_{(1,2) \rightarrow \text{لغزش به بالا}} + \underbrace{0.05 [0 + 0.9(9)]}_{(2,2) \rightarrow \text{لغزش به پایین}} = 9 + 0 + 0.405 = 9.405,$$

$$V_2(1, 2) = \underbrace{0.9 [0 + 0.9(9)]}_{(2,2) \rightarrow \text{پایین}} + \underbrace{0.05 [0]}_{(1,1) \rightarrow \text{چپ}} + \underbrace{0.05 [-10]}_{(1,3) \rightarrow \text{لغزش راست}} = 7.29 - 0.5 = 6.79,$$

$$V_2(2, 1) = \underbrace{0.9 [0 + 0.9(9)]}_{(2,2) \rightarrow \text{راست}} = 7.29, \quad V_2(1, 1) = 0 \text{ (همه‌ی همسایه‌ها هنوز ارزش صفر دارند)}.$$

جمع‌بندی دو ایتريشن:

s	V_0	V_1	V_2
(1, 1)	0	0	0
(1, 2)	0	0	6.79
(2, 1)	0	0	7.29
(2, 2)	0	9	9.405
(1, 3)	0	0	0
(2, 3)	0	0	0

(ب) به‌روزرسانی TD(0):

$$V(s) \leftarrow V(s) + \alpha [r + \gamma V(s') - V(s)], \quad \alpha = 0.1, \gamma = 0.9.$$

همه‌ی مقادیر از صفر آغاز می‌شوند و تجربه‌ها را به ترتیب اعمال می‌کنیم.

مسیر ۱: $\bullet(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$

$$(1, 1) \rightarrow (1, 2) : r = \bullet, V(1, 1) \leftarrow \bullet + \bullet/1[\bullet + \bullet/9(\bullet) - \bullet] = \bullet.$$

$$(1, 2) \rightarrow (1, 3) : r = -1\bullet, V(1, 2) \leftarrow \bullet + \bullet/1[-1\bullet + \bullet/9(\bullet) - \bullet] = -1.$$

مسیر ۲: $\bullet(1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow (2, 3)$

$$(1, 1) \rightarrow (1, 2) : r = \bullet, V(1, 1) \leftarrow \bullet + \bullet/1[\bullet + \bullet/9(-1) - \bullet] = -\bullet/9.$$

$$(1, 2) \rightarrow (2, 2) : r = \bullet, V(1, 2) \leftarrow -1 + \bullet/1[\bullet + \bullet/9(\bullet) - (-1)] = -\bullet/9.$$

$$(2, 2) \rightarrow (2, 3) : r = +1\bullet, V(2, 2) \leftarrow \bullet + \bullet/1[1\bullet + \bullet/9(\bullet) - \bullet] = 1.$$

مقادیر نهایی: $V(2, 1) = \bullet$ و $V(2, 2) = 1, V(1, 2) = -\bullet/9, V(1, 1) = -\bullet/9$ (دیده نشده).

(ج) به روزرسانی SARSA (کنش انتخاب شده در همه جا «راست» است، پس $a = a' = \text{راست}$):

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma Q(s', a') - Q(s, a)], \quad \alpha = \bullet/1, \gamma = \bullet/9, Q_\bullet = \bullet.$$

مسیر ۱:

$$(1, 1), R : r = \bullet, Q((1, 1), R) \leftarrow \bullet + \bullet/1[\bullet + \bullet/9 Q((1, 2), R) - \bullet] = \bullet.$$

$$(1, 2), R : r = -1\bullet, Q((1, 2), R) \leftarrow \bullet + \bullet/1[-1\bullet + \bullet/9(\bullet) - \bullet] = -1.$$

مسیر ۲:

$$(1, 1), R : r = \bullet, Q((1, 1), R) \leftarrow \bullet + \bullet/1[\bullet + \bullet/9(-1) - \bullet] = -\bullet/9.$$

$$(1, 2), R : r = \bullet, Q((1, 2), R) \leftarrow -1 + \bullet/1[\bullet + \bullet/9(\bullet) - (-1)] = -\bullet/9.$$

$$(2, 2), R : r = +1\bullet, Q((2, 2), R) \leftarrow \bullet + \bullet/1[1\bullet + \bullet/9(\bullet) - \bullet] = 1.$$

مقادیر نهایی SARSA: $Q((2, 2), R) = 1, Q((1, 2), R) = -\bullet/9, Q((1, 1), R) = -\bullet/9$.

(د) به روزرسانی Q-learning:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)].$$

تنها کنش «راست» تا کنون به روز شده و بقیه کنش ها در همه ی حالت ها هنوز صفرند.

مسیر ۱: کاملاً مانند SARSA می شود، زیرا در هر گام $\max_{a'} Q(s', a') = \bullet$ است:

$$Q((1, 1), R) = \bullet, \quad Q((1, 2), R) = -1.$$

مسیر ۲:

$$(1, 1), R : r = \bullet, \max_{a'} Q((1, 2), a') = \max(-1, \bullet, \bullet, \bullet) = \bullet,$$

$$Q((1, 1), R) \leftarrow \bullet + \bullet/1[\bullet + \bullet/9(\bullet) - \bullet] = \bullet.$$

$$(1, 2), R : r = \bullet, \max_{a'} Q((2, 2), a') = \bullet, Q((1, 2), R) \leftarrow -1 + \bullet/1[\bullet + \bullet/9(\bullet) - (-1)] = -\bullet/9.$$

$$(2, 2), R : r = +1\bullet, Q((2, 2), R) \leftarrow \bullet + \bullet/1[1\bullet + \bullet/9(\bullet) - \bullet] = 1.$$

مقادیر نهایی Q-learning: $Q((2, 2), R) = 1, Q((1, 2), R) = -\bullet/9, Q((1, 1), R) = \bullet$.
مقایسه. دو روش تنها در یک گام آپدیت متفاوت می دهند: گام اول مسیر ۲، یعنی $(1, 1)$ با کنش «راست» و گذار به $(1, 2)$.

• SARSA در هدف به روزرسانی از ارزش کنش واقعا/انتخاب شده یعنی «راست»، یعنی $Q((1, 2), \text{راست}) = 1$ ، استفاده می‌کند، پس مقدار را به 0.9 - می‌رساند.

• Q-learning در هدف به روزرسانی از جمله‌ی $Q((1, 2), a')$ $\max_{a'} Q$ استفاده می‌کند؛ چون کنش‌های دیگر $(1, 2)$ هنوز صفر (خوش‌بینانه) هستند، این ماکسیمم 0 است و مقدار در 0 باقی می‌ماند.

در یک جمله: این گام متفاوت است چون SARSA از ارزش کنش اجراشده‌ی «راست» (که پیش‌تر به‌خاطر تجربه‌ی 10 - جریمه شده بود) استفاده می‌کند، اما Q-learning با گرفتن بیشینه روی کنش‌ها آن جریمه را نادیده می‌گیرد و به کنش بهتری که هنوز آزموده نشده تکیه می‌کند.
(ه) در ارزیابی مستقیم، برای هر حالت میانگین بازده‌های تخفیف‌خورده‌ی مشاهده‌شده از آن حالت به بعد را می‌گیریم ($\gamma = 0.9$).

مسیر ۱ $((1, 1) \rightarrow (1, 2) \rightarrow (1, 3))$: دنباله‌ی پاداش‌ها $0, -10$.

$$G(1, 1) = 0 + 0.9(-10) = -9, \quad G(1, 2) = -10.$$

مسیر ۲ $((1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow (2, 3))$: دنباله‌ی پاداش‌ها $0, 0, +10$.

$$G(1, 1) = 0 + 0.9(0) + 0.9^2(10) = 8.1, \quad G(1, 2) = 0 + 0.9(10) = 9, \quad G(2, 2) = 10.$$

میانگین‌گیری روی حالت‌های دیده‌شده:

s	returns	$\hat{V}^\pi(s)$
$(1, 1)$	-9, 8.1	$\frac{-9+8.1}{2} = -0.45$
$(1, 2)$	-10, 9	$\frac{-10+9}{2} = -0.5$
$(2, 2)$	10	10

کدام حالت‌ها تخمین ندارند؟ خانه‌ی $(2, 1)$ در هیچ یک از دو مسیر دیده نشده، پس هیچ تخمینی ندارد (خانه‌های پایانی $(1, 3)$ و $(2, 3)$ هم ارزش ندارند).

ارتباط با sample efficiency. ارزیابی مستقیم هر حالت را مستقل از بقیه و فقط از روی بازده‌های کامل مشاهده‌شده تخمین می‌زند و از ساختار مارکوفی/رابطه‌ی Bellman میان حالت‌ها استفاده نمی‌کند؛ بنابراین اطلاعات را میان حالت‌ها به اشتراک نمی‌گذارد و به داده‌ی بیشتری نیاز دارد و برای حالتی مانند $(2, 1)$ که دیده نشده هیچ چیز نمی‌گوید. در مقابل TD با استفاده از تخمین فعلی $V(s')$ در نمونه $(\text{sample} = r + \gamma V(s'))$ اطلاعات یک تجربه را به حالت‌های پیشین منتشر می‌کند و در هر گام (نه فقط در پایان اپیزود) به‌روزرسانی می‌کند، پس از هر نمونه بهره‌ی بیشتری می‌برد و معمولاً sample efficiency بالاتری دارد.

۳. (۱۵ نمره)

در یک MDP دو سیاست π_1 و π_2 با توابع ارزش V_1 و V_2 داریم. سیاست جدید π_3 که به صورت

$$\pi_3 = \frac{1}{4}\pi_1 + \frac{1}{4}\pi_2$$

تعریف می‌شود به این صورت است که در هر گام به احتمال یک دوم مطابق π_1 و به احتمال یک دوم مطابق π_2 عمل می‌کند. تابع ارزش این سیاست را V_3 می‌نامیم. آیا می‌توان گفت $V_3 = \frac{1}{4}V_1 + \frac{1}{4}V_2$ است؟ اثبات کنید یا مثال نقض بیاورید.

حل.

پاسخ کوتاه: **به‌طور کلی خیر**؛ رابطه‌ی $V_3 = \frac{1}{4}V_1 + \frac{1}{4}V_2$ لزوماً برقرار نیست. در ادامه با یک مثال نقض این موضوع را نشان می‌دهیم و سپس دلیل شهودی و صوری نادرستی آن را توضیح می‌دهیم.

نکته‌ی کلیدی — دو نوع «آمیختن» سیاست. باید میان دو کار متفاوت تمایز گذاشت:

- یک بار در ابتدای اپیزود سکه بیندازیم و تا انتها به همان سیاست (π_1 یا π_2) پایبند بمانیم. ارزش این کار دقیقاً $\frac{1}{4}V_1 + \frac{1}{4}V_2$ می‌شود، چون بازدهی مورد انتظار میانگین دو بازدهی جداگانه است.
- آنچه در صورت مسأله تعریف شده: در هر گام به‌طور مستقل سکه انداختن. این یک سیاست مارکوفی تصادفی است که در هر حالت با احتمال $\frac{1}{4}$ کنش π_1 و با احتمال $\frac{1}{4}$ کنش π_2 را برمی‌گزیند. در این حالت انتخاب‌ها در طول مسیر «ضرب» می‌شوند و ارزش، تابعی غیرخطی از سیاست است؛ بنابراین معمولاً با میانگین دو ارزش برابر نیست.

مثال نقض. MDP زیر را با ضریب تخفیف $\gamma = \frac{1}{4}$ در نظر بگیرید. حالت‌ها A (شروع)، B ، C و یک حالت پایانی G ($V(G) = 0$) هستند و در هر حالت دو کنش a و b موجود است. همه‌ی گذارها قطعی‌اند:

- در A : کنش a با پاداش 0 به B می‌رود و کنش b با پاداش 0 به C می‌رود.
 - در B : کنش a با پاداش 8 به G می‌رود و کنش b با پاداش 0 به G می‌رود.
 - در C : کنش b با پاداش 8 به G می‌رود و کنش a با پاداش 0 به G می‌رود.
- دو سیاست قطعی را می‌گیریم: π_1 که همیشه کنش a را می‌زند و π_2 که همیشه کنش b را می‌زند. محاسبه‌ی V_1 و V_2 در حالت A :

$$V_1(A) = 0 + \gamma(\lambda + \gamma \cdot 0) = \frac{1}{4} \times 8 = 2 \quad (\pi_1 : A \xrightarrow{a} B \xrightarrow{a} G),$$

$$V_2(A) = 0 + \gamma(\lambda + \gamma \cdot 0) = \frac{1}{4} \times 8 = 2 \quad (\pi_2 : A \xrightarrow{b} C \xrightarrow{b} G).$$

پس

$$\frac{1}{4}V_1(A) + \frac{1}{4}V_2(A) = \frac{1}{4}(2) + \frac{1}{4}(2) = 1.$$

محاسبه‌ی V_3 در حالت A : سیاست π_3 در هر حالت با احتمال $\frac{1}{4}$ کنش a و با احتمال $\frac{1}{4}$ کنش b را می‌زند. ابتدا ارزش حالت‌های میانی زیر π_3 :

$$V_3(B) = \frac{1}{4} \underbrace{(8)}_a + \frac{1}{4} \underbrace{(0)}_b = 2, \quad V_3(C) = \frac{1}{4} \underbrace{(0)}_a + \frac{1}{4} \underbrace{(8)}_b = 2.$$

و در نتیجه

$$V_3(A) = \frac{1}{4}(0 + \gamma V_3(B)) + \frac{1}{4}(0 + \gamma V_3(C)) = \frac{1}{4}(\frac{1}{4} \times 2) + \frac{1}{4}(\frac{1}{4} \times 2) = \frac{1}{8}.$$

بنابراین

$$V_3(A) = \frac{1}{8} \neq 1 = \frac{1}{4}V_1(A) + \frac{1}{4}V_2(A),$$

و ادعای مسأله رد می‌شود.

شهود مثال. هر دو سیاست π_1 و π_2 در این محیط «هماهنگ» عمل می‌کنند: کنش اول تعیین می‌کند به کدام شاخه (B یا C) برویم و کنش دوم باید همان کنش باشد تا پاداش 8 گرفته شود. اما π_3 در هر گام مستقل سکه می‌اندازد، پس با احتمال $\frac{1}{4}$ کنش دوم با کنش اول ناسازگار می‌شود و پاداش 0 از دست می‌رود. این «از دست رفتن هماهنگی» چیزی است که میانگین‌گیری ساده‌ی $\frac{1}{4}V_1 + \frac{1}{4}V_2$ آن را نمی‌بیند.

بررسی ریاضیاتی. تابع ارزش V_3 نقطه‌ی ثابت معادله‌ی بلمن خود π_3 است:

$$V_3(s) = \sum_a \left(\frac{1}{4}\pi_1(a | s) + \frac{1}{4}\pi_2(a | s) \right) \sum_{s'} T(s, a, s') [R + \gamma V_3(s')],$$

یعنی خود V_3 در سمت راست ظاهر می‌شود. اما $\frac{1}{4}V_1 + \frac{1}{4}V_2$ نقطه‌ای ثابت معادله‌ای است که در آن V_1 فقط تحت دینامیک π_1 و V_2 فقط تحت دینامیک π_2 ظاهر می‌شوند:


$$\frac{1}{4}V_1(s) + \frac{1}{4}V_2(s) = \sum_a \left(\frac{1}{4}\pi_1(a|s)[\dots V_1(s')] + \frac{1}{4}\pi_2(a|s)[\dots V_2(s')] \right).$$

چون در حالت کلی $V_1 \neq V_2$ ، این دو معادله یکی نیستند و دو نقطه‌ای ثابت متفاوت دارند؛ پس دلیلی ندارد جواب‌هایشان برابر باشد.

چه وقت تساوی برقرار می‌شود؟ اگر $\pi_1 = \pi_2$ باشند، یا اگر دینامیک و ارزش‌ها طوری باشند که در همه‌ی حالت‌ها $V_1(s) = V_2(s)$ شود (مثلاً محیط تک‌گامی که در آن آینده اهمیتی ندارد، یا $\gamma = 0$)، آنگاه دو معادله‌ی بالا یکی می‌شوند و $V_3 = \frac{1}{4}V_1 + \frac{1}{4}V_2$ به دست می‌آید. اما در حالت کلی چنین نیست.

۴. (۱۸ نمره)

فرآیند تصمیم‌گیری مارکوف (MDP) که در شکل زیر آمده است را با ضریب تخفیف $\gamma = 0.5$ در نظر بگیرید که در آن حالت‌ها با حروف A ، B و C نشان داده شده‌اند. روی هر یال یک حرف کوچک نوشته شده که یکی از کنش‌های موجود است و یال مربوطه گذار متناظر با انجام آن کنش را نشان می‌دهد. عدد صحیح روی هر یال نیز پاداش کسب‌شده از آن کنش است. تمام گذرها با احتمال ۱ به وقوع می‌پیوندند و تنها گذار از حالت C با کنش x تصادفی است: با انجام کنش x در حالت C پاداش ۸ دریافت می‌شود و محرک با احتمال $\frac{1}{4}$ به حالت A می‌رود و با احتمال $\frac{3}{4}$ در حالت C باقی می‌ماند.



شکل ۱: گراف فرآیند تصمیم‌گیری مارکوف.

با در نظر گرفتن این فرآیند، به سؤالات زیر پاسخ دهید.

(آ) سیاست اولیه π_1 را در نظر بگیرید که به صورت تصادفی و با احتمال برابر در هر حالت یکی از کنش‌های موجود در آن حالت را انتخاب می‌کند. حال فرض کنید تابع ارزش حالت‌های اولیه را به صورت $V_1(A) = 2$ و $V_1(B) = V_1(C) = 2$ در نظر بگیریم. یک مرحله از الگوریتم ارزیابی سیاست π_1 را اجرا کنید تا به تابع ارزش‌گذاری جدید برای حالت‌ها برسید.

(ب) بر اساس تابع ارزش‌گذاری جدید و به صورت حریصانه، سیاست قطعی جدید π_2 را به دست آورید.

(ج) سیاست قطعی π را در نظر بگیرید. اثبات کنید اگر سیاست جدید π' به صورت حریصانه از V^π به دست آمده باشد، آنگاه سیاست π' بهتر یا مساوی π است، یا به عبارتی برای تمام حالت‌ها داریم $V^{\pi'}(s) \geq V^\pi(s)$. هم چنین اثبات کنید اگر تساوی برای تمام حالت‌ها رخ دهد آنگاه π' حتماً سیاست بهینه است.

حل. پیش از حل، کنش‌های موجود در هر حالت و گذارهایشان را جمع‌بندی می‌کنیم ($\gamma = 0.5$):

- حالت A : کنش x با پاداش ۴ به B ; کنش y با پاداش ۲ به C (هر دو با احتمال ۱).
- حالت B : کنش y با پاداش ۰ به A ; کنش x با پاداش ۲ به C (هر دو با احتمال ۱).
- حالت C : کنش y با پاداش ۱ به B (احتمال ۱); کنش x با پاداش ۸ که با احتمال $\frac{1}{4}$ به A و با احتمال $\frac{3}{4}$ در C می‌ماند.

(I) یک گام ارزیابی سیاست به این صورت است:

$$V_{\text{new}}(s) = \sum_a \pi_1(a | s) \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_{\text{old}}(s')],$$

که در آن π_1 یکنواخت است، پس در هر حالت وزن هر کنش $\frac{1}{2}$ می‌شود و مقادیر قبلی $V_{\text{old}}(A) = V_{\text{old}}(B) = V_{\text{old}}(C) = 2$ هستند. ابتدا ارزش کنش‌ها را حساب می‌کنیم:

حالت A :

$$Q(A, x) = 4 + 0.5 V_{\text{old}}(B) = 4 + 0.5(2) = 5, \quad Q(A, y) = 2 + 0.5 V_{\text{old}}(C) = 2 + 0.5(2) = 3, \\ V_{\text{new}}(A) = \frac{1}{2}(5) + \frac{1}{2}(3) = 4.$$

حالت B :

$$Q(B, y) = 0 + 0.5 V_{\text{old}}(A) = 0 + 1 = 1, \quad Q(B, x) = 2 + 0.5 V_{\text{old}}(C) = 2 + 1 = 3, \\ V_{\text{new}}(B) = \frac{1}{2}(1) + \frac{1}{2}(3) = 2.$$

حالت C : (کنش x تصادفی است)

$$Q(C, x) = 8 + 0.5 \left[\frac{1}{4} V_{\text{old}}(A) + \frac{3}{4} V_{\text{old}}(C) \right] = 8 + 0.5 \left[\frac{1}{4}(2) + \frac{3}{4}(2) \right] = 8 + 0.5(2) = 9, \\ Q(C, y) = 1 + 0.5 V_{\text{old}}(B) = 1 + 1 = 2, \quad V_{\text{new}}(C) = \frac{1}{2}(9) + \frac{1}{2}(2) = 5.5.$$

جمع‌بندی تابع ارزش‌گذاری جدید:

s	$V_{\text{old}}(s)$	$V_{\text{new}}(s)$
A	2	4
B	2	2
C	2	5.5

(ب) سیاست حریصانه، در هر حالت کنشی را انتخاب می‌کند که $Q(s, a)$ را بیشینه کند، جایی که این بار از تابع ارزش جدید بخش قبل، یعنی $V(A) = 4, V(B) = 2, V(C) = 5.5$ ، استفاده می‌کنیم:

$$\pi_2(s) = \arg \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')].$$

حالت A :

$$Q(A, x) = 4 + 0.5(2) = 5, \quad Q(A, y) = 2 + 0.5(5.5) = 4.75 \Rightarrow \pi_2(A) = x.$$

حالت B :

$$Q(B, y) = 0 + 0.5(4) = 2, \quad Q(B, x) = 2 + 0.5(5.5) = 4.75 \Rightarrow \pi_2(B) = x.$$

حالت C :

$$Q(C, x) = 8 + 0.5 \left[\frac{1}{4}(4) + \frac{3}{4}(5.5) \right] = 8 + 0.5(5.125) = 10.5625, \quad Q(C, y) = 1 + 0.5(2) = 2 \Rightarrow \pi_2(C) = x.$$

پس سیاست قطعی جدید عبارت است از:

$$\pi_2(A) = x, \quad \pi_2(B) = x, \quad \pi_2(C) = x.$$

(ج) **قضیهی بهبود سیاست.** فرض کنید π' به صورت حریصانه از V^π ساخته شده باشد، یعنی برای هر حالت

$$\pi'(s) = \arg \max_a Q^\pi(s, a), \quad Q^\pi(s, a) := \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^\pi(s')].$$

می‌خواهیم نشان دهیم $V^{\pi'}(s) \geq V^\pi(s)$ برای همه‌ی حالت‌ها.

گام ۱ (نامساوی پایه). چون π' کنش بیشینه‌کننده را برمی‌گزیند و $\pi(s)$ صرفاً یکی از کنش‌های ممکن است:

$$Q^\pi(s, \pi'(s)) = \max_a Q^\pi(s, a) \geq Q^\pi(s, \pi(s)) = V^\pi(s). \quad (*)$$

گام ۲ (بازکردن نامساوی). از (*) شروع می‌کنیم و از این‌که $Q^\pi(s, \pi'(s)) = \mathbb{E}[R + \gamma V^\pi(s') \mid s_t = s, a_t = \pi'(s_t)]$ است بارها استفاده می‌کنیم. با اعمال دوباره‌ی (*) روی $V^\pi(s')$ در هر مرحله:

$$\begin{aligned} V^\pi(s) &\leq Q^\pi(s, \pi'(s)) = \mathbb{E}[R_{t+1} + \gamma V^\pi(s_{t+1}) \mid s_t = s, a_t = \pi'(s_t)] \\ &\leq \mathbb{E}[R_{t+1} + \gamma Q^\pi(s_{t+1}, \pi'(s_{t+1})) \mid s_t = s, \pi'] \\ &= \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 V^\pi(s_{t+2}) \mid s_t = s, \pi'] \\ &\vdots \\ &\leq \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \mid s_t = s, \pi'] = V^{\pi'}(s). \end{aligned}$$

در هر خط، از یکنواختی امید ریاضی و از نامساوی (*) استفاده کرده‌ایم؛ چون $0 \leq \gamma < 1$ ، دنباله همگرا و جمله‌ی باقی‌مانده صفر می‌شود. نتیجه:

$V^{\pi'}(s) \geq V^\pi(s) \quad \text{برای همه‌ی } s.$

بخش دوم — اگر تساوی برای همه‌ی حالت‌ها برقرار شود، π' بهینه است. فرض کنید برای همه‌ی s داشته باشیم $V^{\pi'}(s) = V^\pi(s)$ ؛ این مقدار مشترک را $V(s)$ می‌نامیم. چون π' حریصانه نسبت به $V^\pi = V$ است و $V^{\pi'}$ نقطه‌ی ثابت خود π' است، داریم

$$V(s) = V^{\pi'}(s) = \sum_{s'} T(s, \pi'(s), s') [R + \gamma V^{\pi'}(s')] = \max_a \sum_{s'} T(s, a, s') [R + \gamma V(s')].$$

در تساوی آخر از این استفاده کردیم که $\pi'(s) = \arg \max_a Q^\pi(s, a)$ و $V^{\pi'} = V^\pi = V$. اما رابطه‌ی به‌دست‌آمده

$$V(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')]$$

دقیقاً معادله‌ی بهینگی بلمن است.

۵. (۱۷ نمره) در بازی micro - blackjack در هر مرحله از دسته کارت موجود یک کارت را بیرون می‌کشید و سپس دوباره آن را برمی‌گردانید و برمی‌زنید. کارت بیرون کشیده شده همیشه با احتمال برابر، مساوی یک از ۳ عدد ۲ و ۳ و ۴ است. اگر جمع اعداد کارت‌های بیرون کشیده شده کمتر از ۶ بود، می‌توانید باز هم به بازی ادامه دهید و یا اینکه متوقف شوید. اما اگر جمع این اعداد بیشتر از ۵ بود بازی به اتمام می‌رسد و دیگر نمی‌توانید کارتی بیرون بکشید.

در انتهای بازی امتیاز شما برابر با جمع کارت‌های بیرون کشیده شده است اگر این مقدار کمتر از ۶ باشد و در غیر این صورت برابر ۰ است.

این بازی را به صورت یک MDP با ضریب تخفیف $\gamma = 1$ مدل می‌کنیم. هر حالت را به صورت زوج (n, status) نمایش می‌دهیم که در آن n جمع فعلی کارت‌های بیرون کشیده شده است و status وضعیت بازی را مشخص می‌کند: مقدار C به این معناست که بازی در جریان است و عامل باید یکی از دو کنش draw (کشیدن یک کارت دیگر) یا stop (توقف) را انتخاب کند، و مقدار Done به این معناست که بازی به پایان رسیده است (حالت پایانی). در آغاز بازی در حالت $(0, C)$ قرار داریم. هرگاه عامل کنش stop را انتخاب کند یا با کشیدن کارت جمع کارت‌ها از ۵ بیشتر شود، به حالت پایانی Done می‌رویم و بازی تمام می‌شود.

(آ) با استفاده از این مدل‌سازی، فضای حالت این بازی چیست؟

(ب) تابع reward در این مسئله به چه شکل است؟

(ج) با استفاده از الگوریتم Value Iteration مقدار بهینه هر state و همچنین policy بهینه را پیدا کنید.

(د) فرض کنید به جای پیدا کردن این مقادیر به صورت offline بخواهیم از Q-Learning استفاده کنیم. فرض کنید به مقدار بسیار زیادی بازی انجام داده‌اید و تعداد بسیار زیادی سمپل دارید. ولی به طرز عجیبی در همه‌ی این سمپل‌ها، هر بار که کارتی بیرون کشیده‌اید، مقدار روی آن برابر با ۲ بوده است. حد نهایی توابع Q در صورتی که مقدار اولیه آن‌ها ۰ و learning rate برابر با $\frac{1}{4}$ باشد چقدر است؟

(ه) مقادیر بهینه‌ی V^* و Q^* به دست آمده در بخش ۳ را به عنوان مقادیر درست (ground truth) در نظر بگیرید. حالت $s = (4, C)$ را در نظر بگیرید که در آن مقادیر یادگرفته شده‌ی فعلی به صورت $Q((4, C), \text{draw}) = 3/0$ و $Q((4, C), \text{stop}) = 4/0$ هستند. تحت سیاست ϵ -greedy با $\epsilon = 0/4$ ، احتمال انتخاب هر کنش و مقدار Q مورد انتظار کنش انتخاب شده را حساب کنید.

(و) regret هر گام را به صورت $\text{regret}_t = V^*(s_t) - Q^*(s_t, a_t)$ تعریف می‌کنیم که در آن a_t کنشی است که واقعاً انجام شده و V^* و Q^* همان مقادیر بخش ۳ هستند. اجرای اکتشافی زیر شامل دو بازی کوتاه است؛ هرگاه به حالت پایانی Done برسیم، بازی از نو در حالت $(0, C)$ آغاز می‌شود. ستون s_{t+1} حالت بعدی (شامل کارت کشیده شده در کنش draw) را نشان می‌دهد. برای این اجرا، regret تجمعی را محاسبه کنید.

t	s_t	a_t	s_{t+1}
۱	$(0, C)$	draw	$(2, C)$
۲	$(2, C)$	stop	Done
۳	$(0, C)$	draw	$(4, C)$
۴	$(4, C)$	draw	Done (bust)

حل.

(آ) هر حالت غیرپایانی به صورت (n, C) است که در آن n جمع کارت‌های کشیده شده تا کنون و کمتر از ۶ است. از آنجا که کوچک‌ترین کارت ۲ است، جمع ۱ هرگز قابل دستیابی نیست و تنها جمع‌های قابل دسترس کمتر از ۶ برابرند با $\{0, 2, 3, 4, 5\}$. به محض آن‌که جمع از ۵ بیشتر شود یا عامل کنش stop را انتخاب کند، به حالت پایانی یکتای Done می‌رویم. بنابراین فضای حالت برابر است با:

$$S = \{(0, C), (2, C), (3, C), (4, C), (5, C), \text{Done}\}.$$

یعنی پنج حالت غیرپایانی و یک حالت پایانی.

(ب) امتیاز تنها در پایان بازی به دست می‌آید، پس reward را روی گذار به حالت پایانی تعریف می‌کنیم. اگر عامل در حالت (n, C) کنش stop را بزند، بازی با امتیاز n تمام می‌شود؛ و اگر کنش draw را بزند، در صورت ادامه‌ی بازی یا حتی bust شدن (جمع ≥ 6) هیچ امتیازی نمی‌گیرد:

$$R((n, C), \text{stop}, \text{Done}) = n,$$

$$R((n, C), \text{draw}, s') = 0 \quad \text{برای هر } s'.$$

حالت Done جذب‌کننده است و هیچ پاداش دیگری ندارد. توجه کنید که bust شدن خود به خود امتیاز صفر می‌دهد، چون به Done می‌رویم بدون آن‌که stop زده باشیم.
(ج) با $\gamma = 1$ معادله‌ی بهینگی Bellman به این صورت است:

$$Q((n, C), \text{stop}) = n, \quad Q((n, C), \text{draw}) = \frac{1}{3} \sum_{c \in \{2, 3, 4\}} V^*((n + c, C)),$$

که در آن قرارداد می‌کنیم برای هر جمع $6 \geq$ (یعنی bust) مقدار $V^* = 0$ باشد، و $V^*(s) = \max(Q(s, \text{stop}), Q(s, \text{draw}))$.

Value Iteration را با $V \equiv 0$ آغاز می‌کنیم. چون جمع کارت‌ها همواره صعودی است، گراف گذارها بدون دور است و الگوریتم پس از چند گام همگرا می‌شود:

s	V_0	V_1	V_2	$V_3 = V^*$
$(0, C)$	0	0	3	10/3
$(2, C)$	0	2	3	3
$(3, C)$	0	3	3	3
$(4, C)$	0	4	4	4
$(5, C)$	0	5	5	5

از V_3 به بعد مقادیر تغییری نمی‌کنند، پس همگرا شده‌ایم. مقادیر بهینه‌ی Q عبارت‌اند از:

s	$Q^*(s, \text{draw})$	$Q^*(s, \text{stop})$	$\pi^*(s)$
$(0, C)$	$10/3 \approx 3.33$	0	draw
$(2, C)$	3	2	draw
$(3, C)$	$5/3 \approx 1.67$	3	stop
$(4, C)$	0	4	stop
$(5, C)$	0	5	stop

برای نمونه در $(2, C)$ کشیدن کارت بهتر است: $Q^*((2, C), \text{draw}) = \frac{1}{3}(V^*(4) + V^*(5) + 0) = \frac{1}{3}(4 + 5 + 0) = 3 > 2$ اما در $(3, C)$ و بالاتر، خطر bust شدن زیاد است و توقف بهینه می‌شود. سیاست بهینه: در جمع‌های 0 و 2 کارت بکش و در 3 و 4 و 5 متوقف شو.

(د) چون در همه‌ی سیمپل‌ها کارت کشیده شده برابر 2 بوده است، Q-Learning عملاً روی یک محیط قطعی آموزش می‌بیند که در آن کنش draw همیشه 2 به جمع اضافه می‌کند. به‌روزرسانی به صورت زیر است:

$$Q(s, a) \leftarrow (1 - \alpha) Q(s, a) + \alpha \left(r + \gamma \max_{a'} Q(s', a') \right), \quad \alpha = \frac{1}{4}.$$

وقتی هدف (target) قطعی باشد، با هر مقدار ثابت $0 < \alpha < 1$ مقدار Q به نقطه‌ی ثابت همان معادله همگرا می‌شود؛ پس مقدار خاص $\alpha = \frac{1}{4}$ روی حد نهایی اثری ندارد و فقط سرعت همگرایی را تعیین می‌کند. کافی است نقطه‌ی ثابت محیط قطعی را پیدا کنیم؛ گذارهای draw (همیشه +2) چنین‌اند:

$$(0, C) \rightarrow (2, C), \quad (2, C) \rightarrow (4, C), \quad (3, C) \rightarrow (5, C), \quad (4, C) \rightarrow \text{Done}, \quad (5, C) \rightarrow \text{Done},$$

که دو مورد آخر bust هستند. با $Q(n, \text{draw}) = V(n + 2)$ و $Q(n, \text{stop}) = n$ از بالا به پایین حساب می‌کنیم:

s	$Q_{\infty}(s, \text{draw})$	$Q_{\infty}(s, \text{stop})$
$(0, C)$	4	0
$(2, C)$	4	2
$(3, C)$	5	3
$(4, C)$	0	4
$(5, C)$	0	5

برای مثال $Q_{\infty}((3, C), \text{draw}) = V(5) = 5$ زیرا در این محیط ساختگی کشیدن کارت در $(3, C)$ همیشه 5 می‌دهد و هرگز bust نمی‌شود. به همین دلیل عاملی که فقط این سمپل‌ها را دیده، به اشتباه فکر می‌کند کشیدن کارت در $(3, C)$ بسیار سودمند است؛ این دقیقاً تفاوت میان مقادیر آموخته‌شده از سمپل‌های اریب و مقادیر بهینه‌ی واقعی بخش 3 را نشان می‌دهد.

(ه) در حالت $(4, C)$ داریم $Q(\text{draw}) = 3/0 > Q(\text{stop}) = 4/0$ پس کنش حریصانه (greedy) همان stop است. با تعداد کنش $|A| = 2$ و $\varepsilon = 0/4$ ، سیاست ε -greedy با احتمال $1 - \varepsilon$ کنش حریص و با احتمال ε یکی از کنش‌ها را به‌طور یکنواخت انتخاب می‌کند:

$$P(\text{stop}) = (1 - \varepsilon) + \frac{\varepsilon}{4} = 0/6 + 0/2 = 0/8, \quad P(\text{draw}) = \frac{\varepsilon}{4} = 0/2.$$

مقدار Q مورد انتظار کنش انتخاب‌شده:

$$\mathbb{E}[Q] = P(\text{stop}) Q(\text{stop}) + P(\text{draw}) Q(\text{draw}) = 0/8 \times 4/0 + 0/2 \times 3/0 = 3/2 + 0/6 = 3/8.$$

(و) با مقادیر درست بخش 3، یعنی

$$V^*(0, C) = \frac{10}{3}, \quad V^*(2, C) = 3, \quad V^*(4, C) = 4,$$

$$Q^*((0, C), \text{draw}) = \frac{10}{3}, \quad Q^*((2, C), \text{stop}) = 2, \quad Q^*((4, C), \text{draw}) = 0,$$

regret هر گام را حساب می‌کنیم:

t	s_t	a_t	$\text{regret}_t = V^*(s_t) - Q^*(s_t, a_t)$
1	$(0, C)$	draw	$\frac{10}{3} - \frac{10}{3} = 0$
2	$(2, C)$	stop	$3 - 2 = 1$
3	$(0, C)$	draw	$\frac{10}{3} - \frac{10}{3} = 0$
4	$(4, C)$	draw	$4 - 0 = 4$

گام‌های 1 و 3 کنش بهینه (draw در جمع 0) را انتخاب کرده‌اند و regret صفر دارند. در گام 2 توقف زود هنگام به جای کشیدن کارت یک واحد regret می‌دهد، و در گام 4 کشیدن پریسک که به bust منجر می‌شود بیشترین regret را دارد. regret تجمعی برابر است با:

$$\sum_{t=1}^4 \text{regret}_t = 0 + 1 + 0 + 4 = 5.$$

۶. (17 نمره) یک محرک در یک MDP با سه حالت $\{X, Y, Z\}$ و دو کنش $\{a, b\}$ به اکتشاف می‌پردازد. پس از چند اپیزود، چهار تایی‌های مشاهده‌شده‌ی (s, a, r, s') به صورت زیر ثبت شده‌اند:

s	a	r	s'
X	a	۳	Y
X	a	۳	Y
X	a	۳	Z
X	b	۱	X
X	b	۱	X
Y	a	۴	Z
Y	a	۴	Z
Y	a	۴	Y
Y	b	۲	X
Z	a	۰	Z
Z	a	۰	Z
Z	b	۵	X

(آ) مدل گذار $\hat{T}(s, a, s')$ را برای هر زوج (s, a) با شمارش و نرمال‌سازی تخمین بزنید.

(ب) مدل پاداش $\hat{R}(s, a, s')$ را از روی پاداش‌های مشاهده‌شده تخمین بزنید.

(ج) با استفاده از $\gamma = 0.9$ و مدل‌های تخمینی $\hat{R}$ و $\hat{T}$ ، یک مرحله از به‌روزرسانی Value Iteration را از $V_1 = 0$ انجام دهید تا V_1 برای هر حالت به‌دست آید، و سپس کنش حریصانه‌ی هر حالت را مشخص کنید.

(د) تحت کنش a ، حالت Z یک حالت absorbing است ($\hat{T}(Z, a, Z) = 1$ و $R = 0$). آیا همگرایی Value Iteration روی این MDP یادگرفته‌شده تضمین‌شده است؟ در یک جمله توضیح دهید.

حل. پیش از حل، مشاهده‌ها را برای هر زوج (s, a) دسته‌بندی می‌کنیم تا شمارش گذارها و پاداش‌ها ساده شود:

- (X, a) : سه نمونه با پیامدهای Y, Y, Z و پاداش ثابت ۳.
- (X, b) : دو نمونه با پیامد X و پاداش ثابت ۱.
- (Y, a) : سه نمونه با پیامدهای Z, Z, Y و پاداش ثابت ۴.
- (Y, b) : یک نمونه با پیامد X و پاداش ۲.
- (Z, a) : دو نمونه با پیامد Z و پاداش ۰.
- (Z, b) : یک نمونه با پیامد X و پاداش ۵.

(آ) مدل گذار تخمینی از شمارش نسبی پیامدها به دست می‌آید:

$$\hat{T}(s, a, s') = \frac{\#\{(s, a) \rightarrow s'\}}{\#\{(s, a)\}}.$$

با نرمال‌سازی شمارش‌ها برای هر زوج (s, a) :

(s, a)	s'	$\hat{T}(s, a, s')$
(X, a)	Y	$2/3$
(X, a)	Z	$1/3$
(X, b)	X	1
(Y, a)	Z	$2/3$
(Y, a)	Y	$1/3$
(Y, b)	X	1
(Z, a)	Z	1
(Z, b)	X	1

هر گذار دیده نشده احتمال ۰ می گیرد و مجموع احتمال ها در هر زوج (s, a) برابر ۱ است.

(ب) مدل پاداش تخمینی، میانگین پاداش های مشاهده شده برای هر سه تایی (s, a, s') است. در این داده ها پاداش تنها به (s, a) بستگی دارد (برای هر زوج، همه ی نمونه ها پاداش یکسان دارند)، پس:

$$\hat{R}(X, a, Y) = \hat{R}(X, a, Z) = ۳, \quad \hat{R}(X, b, X) = ۱,$$

$$\hat{R}(Y, a, Z) = \hat{R}(Y, a, Y) = ۴, \quad \hat{R}(Y, b, X) = ۲,$$

$$\hat{R}(Z, a, Z) = ۰, \quad \hat{R}(Z, b, X) = ۵.$$

(ج) یک گام Value Iteration از $V_0 \equiv ۰$ با $\gamma = ۰.۹$ به این صورت است:

$$V_1(s) = \max_a \sum_{s'} \hat{T}(s, a, s') [\hat{R}(s, a, s') + \gamma V_0(s')].$$

چون $V_0 \equiv ۰$ ، جمله ی $\gamma V_0(s')$ حذف می شود و $V_1(s)$ صرفاً بیشینه ی پاداش آنی مورد انتظار روی کنش هاست. مقدار کنش ها را حساب می کنیم:
حالت X :

$$Q(X, a) = \frac{۲}{۳}(۳) + \frac{۱}{۳}(۳) = ۳, \quad Q(X, b) = ۱ \cdot (۱) = ۱ \Rightarrow V_1(X) = ۳, \pi(X) = a.$$

حالت Y :

$$Q(Y, a) = \frac{۲}{۳}(۴) + \frac{۱}{۳}(۴) = ۴, \quad Q(Y, b) = ۱ \cdot (۲) = ۲ \Rightarrow V_1(Y) = ۴, \pi(Y) = a.$$

حالت Z :

$$Q(Z, a) = ۱ \cdot (۰) = ۰, \quad Q(Z, b) = ۱ \cdot (۵) = ۵ \Rightarrow V_1(Z) = ۵, \pi(Z) = b.$$

جمع بندی نتیجه ی این گام:

s	$V_1(s)$	greedy action
X	3	a
Y	4	a
Z	5	b

(د) بله، همگرایی تضمین شده است، زیرا همگرایی در Value Iteration بدون توجه به ساختار MDP تضمین شده است.