

۴۵۳۱۰۲۶۶۱

Subject:

Date: مردی ۱۳۹۵

۱- الف الف درست

تابع ارزش به دلیل پیوسته بودن امکان است خطی طول بلند تا همگرا شود.
همچنین از یک جای به بعد ارزشی که در هر استیست بهینه است را خطی قبل تر
از همگرای تابع ارزش بدست می آورده پس همگرای به آن زودتر رخ می دهد
ب) نادرست

Q-learning یک الوریفر off-policy است پس می تواند مستقل از سیاست بهینه تر
مربط به ارزش بهینه چی است؟ معادله بهینه ارزش و در نهایت سیاست بهینه تر
بیدار
مجموع درست

دوره iteration الوریفر value iteration و $Q(S^i, A)$ به چیدگی زمانی داریم
در هر iteration الوریفر policy iteration دو بخش π و Q دارد
درباره $Q(S^i)$ اول به دلیل عدم وجود max روی ارزش ها $Q(S^i)$ را در

بخش دوم که مربوط به $R(S^i, A^i) + \gamma V(S^i)$ است $\arg \max_a T(S^i, A^i) = Q(S^i, A)$
به چیدگی زمانی داریم پس:

DAT
پس اگر A به A^i هر دو الوریفر به چیدگی زمانی $Q(S^i)$ دارند

$$E\left(\sum_{t=0}^{\infty} \gamma^t (R_t + c)\right) = V^{\pi}(s) + \sum_{t=0}^{\infty} \gamma^t c = V^{\pi}(s) + \frac{c}{1-\gamma} \quad \text{درست (د)}$$

پس به تمامی حالات مقدار مثبت و ثابت $\frac{c}{1-\gamma}$ اضافه می شود و ترتیب و سیاست

بهینه تغییر نمی کند (اگر $\gamma = 1$ بود و agent می توانست تا ابد پاداش نگزارد غلط میشد)
در محیط

نادرست (ه)

هر چه γ به صفر نزدیکتر باشد، سیاست بهینه پاداش زود هنگام را می خواهد اما اگر

γ به یک نزدیک شود سیاست بهینه آینده نگر تر می شود و پاداش های بزرگ دیر هنگام را

نیز می خواهد

درست (و)

وقتی که یک finite horizon MDP است سیاست ما گاملا به تعداد حرکت باقی مانده

بستگی دارد. مثلاً اگر یک حرکت باقی مانده باشد بهترین سیاست انتخاب اکشن با

بیشترین reward است اما اگر ده حرکت مانده باشد بهترین سیاست سرمایه گذاری

برای reward های بهتر در آینده است. پس چون سیاست بهینه به زمان

وابسته شد، non-stationary است

DAT

(الف) تفاوت این دو در یک عبارت است که $Q(s_t, a_t)$ را آپدیت می کند و در

off-policy $\gamma \max_a Q(s_{t+1}, a)$ و در on-policy $\gamma Q(s_{t+1}, a_{t+1})$

این به این معناست که در off-policy مستقل از سیاستی که داریم ارزش استفاده

می کنیم، Q ها را آپدیت می کنیم (Q-learning) و در on-policy با استفاده از

همان سیاستی که داریم در محیط استفاده می کنیم، Q ها را آپدیت می کنیم (SARSA)

(ب) در model-based ما سعی داریم تا R و T هر استیت رو صحیحاً شبیه کنیم

تا با الگوریتم های MDP مسئله را حل کنیم اما در model-free ما R و T

مستقیم در اختیار ما قرار نمی گیرند و ما فقط با محیط و مشاهده نتایج ارزش ها را یاد

می گیریم

۲- الف) در مرحله اول $V_{(1,2)}$ و $V_{(2,1)}$ آیدیت نمی نشوند چون

بیشتر از یک قدم با ترسناک ها حاصل دارند

$$V_{(1,2)} \Rightarrow a=R \Rightarrow \left. \begin{array}{l} 0/9(-1+0) = -9 \\ 0/0.5(0+0) = 0 \\ 0/0.5(0+0) = 0 \end{array} \right\} \Rightarrow -9$$

$$a=D/U \Rightarrow \left. \begin{array}{l} 0/9(0+0) = 0 \\ 0/0.5(0+0) = 0 \\ 0/0.5(-1+0) = -0.5 \end{array} \right\} \Rightarrow -0.5$$

$$a=L \Rightarrow \left. \begin{array}{l} 0/9(0+0) = 0 \\ 0/0.5(0+0) = 0 \\ 0/0.5(0+0) = 0 \end{array} \right\} \Rightarrow 0$$

$$\max_a \Rightarrow a=L$$

پس در مرحله اول: $V_{(1,2)} = 0$

برای بقیه نیز به همین صورت است:

$$V_{(2,2)} \Rightarrow \left. \begin{array}{l} a=R \Rightarrow 9+0+0 = 9 \\ a=D/U \Rightarrow 0+0+0.5 = 0.5 \\ a=L \Rightarrow 0+0+0 = 0 \end{array} \right\} \Rightarrow V_{(2,2)} = 9$$

مرحله دوم: باز هم $V_{(1,1)}$ مفروض شود

$$\left. \begin{aligned} V_{(x,1)} \Rightarrow a=R &\Rightarrow V_1 \times 9 + 0 + 0 = V_1 \times 9 \\ a=D/U &\Rightarrow 0 + 0 + 0/90 \omega = 0/90 \omega \\ a=L &\Rightarrow 0 + 0 + 0 = 0 \end{aligned} \right\} \Rightarrow V_x(x,1) = V_1 \times 9$$

$$\left. \begin{aligned} V_{(1,x)} \Rightarrow a=R &\Rightarrow -9 + 0 + 0/90 \omega = -1/90 \omega \\ a=D &\Rightarrow V_1 \times 9 + 0 - 0/90 \omega = V_1 \times 9 \\ a=U &\Rightarrow 0 + 0 - 0/90 \omega = -0/90 \omega \\ a=L &\Rightarrow 0 + 0 + 0/90 \omega = 0/90 \omega \end{aligned} \right\} \Rightarrow V_x(1,x) = V_1 \times 9$$

$$\left. \begin{aligned} V_{(x,x)} \Rightarrow a=R &\Rightarrow 9 + 0/90 \omega + 0 = 9/90 \omega \\ a=L &\Rightarrow 0 + 0 + 0 = 0 \\ a=U &\Rightarrow 0 + 0 + 0/90 \omega = 0/90 \omega \\ a=D &\Rightarrow 0 + 0/90 \omega + V_1 \times 9 = V_1 \times 9 \end{aligned} \right\} \Rightarrow V_x(x,x) = 9/90 \omega$$

$$TDL \Rightarrow V^{\uparrow}(s) = (1-\alpha)V^{\uparrow}(s) + \alpha(R(s, \pi(s), s') + \gamma V^{\uparrow}(s'))$$

$$V_{(1,1)} = 0 + 0/1 (0 + 0/9 + 0) = 0$$

مسیر اول

$$V_{(1,x)} = 0 + 0/1 (-10 + 0/9 + 0) = -1$$

(با هم مقایسه)

Subject:

Date:

$$V(1,1) = 0 + 0.1 (0 + 0.9(-1)) = -0.09 \quad \text{مسیر دوم:}$$

$$V(1,2) = -1 \times 0.9 + 0.1 (0 + 0.9(0)) = -0.9$$

$$V(2,2) = 0 + 0.1 (1 + 0.9(0)) = 0.1$$

(ج) چون اکشن‌ها ثابت هستند و همه به سمت راست هستند مقادیر Q ها با

روش SARSA برابر با مقادیر V در صحت به دست می‌آید

$$Q((1,1), R) = 0 \quad \text{مسیر اول:}$$

$$Q((1,2), R) = -1$$

$$Q((1,1), R) = -0.09 \quad \text{مسیر دوم:}$$

$$Q((1,2), R) = -0.9$$

$$Q((2,2), R) = 0.1$$

$$Q((1,1), R) = 0$$

(>) مسیر اول:

$$Q((1,2), R) = -1$$

مسیر دوم:

$$Q((1,1), R) \Rightarrow Q((1,2), R) = -1 \text{ اینجا به جای انتخاب } -1$$

$$\text{از } Q((1,1), R) = 0 \text{ استفاده می شود چون } -1 > 0$$

$$\Rightarrow Q((1,1), R) = 0 + 0/1(0) = 0$$

$$Q((1,2), R) = -0.9$$

$$Q((2,2), R) = 1$$

مقادیر Q به جز $Q((1,1), R)$ با قسمت چ کایمان شدند چون در خاص حالت ها

max در اکشن راست بود یا در ترمینال بودیم که $Q = 0$ اما در حالت $Q((1,1), R)$

$$Q((1,2), R) = -1 \text{ و } Q((1,2), L/U/D) = 0 \text{ داشتیم:}$$

Subject:

Date:

(۵) برای حالت های دومسیر

$$V_t(s) = \frac{\delta^0 R_{t+1} + \delta R_{t+1} + \dots + \delta^{n-1} R_{t+n-1}}{n}$$

$$V(1,1) = \frac{(0 + 0.9(-1))}{2} + \frac{(0 + 0.9(1) + (0.9)^2(1))}{2} = -0.45$$

$$V(1,2) = \frac{(1 \times (-1)) + (0 + 0.9(1))}{2} = -0.5$$

$$V(2,2) = \frac{1 + 1}{2} = 1$$

حالت (۲,۱) چون در مسیرها مشاهده نشده تخمین ندارد

در DE ارزش هر حالت مستقل و فقط بر اساس یاداشته هر مسیر

محاسبه می شود و درکی از ارتباط بین حالت ها ندارد و مثلاً از ارزش (۱,۲)

برای آپدیت (۱,۱) استفاده نمی کند

اما در TD تخمین یک حالت را با استفاده از تخمین حالت های بعدی آپدیت

می کنند که این باعث می شود در TD sample efficiency بالاتری داشته باشیم

DAT

۳- گزاره غلط است

اگر π به صورت قطعی بود داشتیم:

$$V^{\pi}(s) = \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi}(s'))$$

اما چون یک توزیع احتمال روی π داریم پس:

$$V^{\pi}(s) = \sum_a \left(\frac{1}{2} \pi_1(a|s) + \frac{1}{2} \pi_2(a|s) \right) \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi}(s'))$$

از فرمول اولیه یک E گرفتیم و به فرمول بالا رسیدیم

$$\Rightarrow V^{\pi}(s) = \frac{1}{2} \sum_a \pi_1(a|s) \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi}(s')) + \frac{1}{2} \sum_a \pi_2(a|s) \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi}(s'))$$

برای اینکه فرمول بالا درست باشد، عبارت $\gamma V^{\pi}(s')$ در حقیقت تکرار باید به ترتیب $V^{\pi}(s)$ و $V^{\pi}(s')$ باشند (بسیطوریست)

مثال نقص: $states = \{s, send\}$ $V(send) = 0$

$action(A) =$ با احتمال یک در کم می ماند و امتیاز می گیرد
 $action(B) =$ با احتمال یک به $send$ می رود و امتیاز می گیرد

$$\gamma = \frac{1}{2}$$

DAT

Subject:

Date:

۱. همواره الکشن A را انتخاب می کند

$$V_1(s) = 10 + \frac{1}{2} V_1(s) \Rightarrow V_1(s) = 20$$

۲. همواره الکشن B را انتخاب می کند

$$V_2(s) = 0 + \frac{1}{2} V(s_{end}) \Rightarrow V_2(s) = 0$$

سوال می گوید:

$$V_3 = \frac{1}{2} \times 20 + 0 = 10$$

حالا همان فرمول صفت قبل را می نویسیم

$$V_3(s) = \frac{1}{2} \left(10 + \frac{1}{2} V_3(s) \right) + \frac{1}{2} \times 0 \Rightarrow V_3(s) = \frac{20}{3}$$

پس گزاره سوال غلط است

DAT

۴- الف) ما را با این فرمول آبدیت می کنیم

$$V_{k+1}^{\pi_1}(s) = \sum_{s'} T(s, \pi_1(s), s') (R(s, \pi_1(s), s') + \gamma V_k^{\pi_1}(s'))$$

در حالت A و B، $T=1$ یعنی ترانزیشن را فضایی که می بینیم به همان جایی که می رویم

در C اینطور نیست. و در هر ۳ استیپ یک توزیع احتمال برای π_1

داریم چون توزیعش یکنواخت است عمل میانیلیں گیری انجام می دهیم

$$V_2^{\pi_1}(A) = \frac{1}{2} \times \left(4 + \frac{1}{2} \times 4 \right) + \frac{1}{2} \left(2 + \frac{1}{2} \times 2 \right) = 4$$

لکه توزیع احتمال π_1

$$V_2^{\pi_1}(B) = \frac{1}{2} \times \left(2 + \frac{1}{2} \times 2 \right) + \frac{1}{2} \left(0 + \frac{1}{2} \times 2 \right) = 2$$

$$V_2^{\pi_1}(C) = \frac{1}{2} \times \left(\frac{3}{4} \times \left(1 + \frac{1}{2} \times 2 \right) + \frac{1}{4} \left(1 + \frac{1}{2} \times 2 \right) \right) + \frac{1}{2} \left(1 + \frac{1}{2} \times 2 \right)$$

← این یک $T(s, \pi_1(s), s')$

است $\rightarrow A \perp C$

$$\Rightarrow V_2^{\pi_1}(C) = 5, 5$$

(ب) را با غرض اول زیر محاسبه می کنیم

$$\pi_Y(s) = \arg \max_a \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi_1}(s'))$$

$$\begin{aligned} \pi_Y(A) = \quad a &\Rightarrow 4 + \frac{1}{2} \times 2 = 5 \\ y &\Rightarrow 2 + \frac{1}{2} \times 5 = 4.5 \end{aligned}$$

$$\begin{aligned} 5 > 4.5 \\ \Rightarrow \pi_Y(A) = a \end{aligned}$$

$$\begin{aligned} \pi_Y(B) = \quad a &\Rightarrow 2 + \frac{1}{2} \times 5 = 4.5 \\ y &\Rightarrow 0 + \frac{1}{2} \times 4 = 2 \end{aligned}$$

$$\begin{aligned} 4.5 > 2 \\ \Rightarrow \pi_Y(B) = a \end{aligned}$$

$$\begin{aligned} \pi_Y(C) \Rightarrow \quad a &\Rightarrow \frac{1}{5} \left(1 + \frac{1}{2} \times 4 \right) + \frac{3}{5} \left(1 + \frac{1}{2} \times 5 \right) = \frac{4.2}{5} \\ y &\Rightarrow 1 + \frac{1}{2} \times 2 = 2 \end{aligned}$$

$$\begin{aligned} \frac{4.2}{5} > 2 \\ \Rightarrow \pi_Y(C) = a \end{aligned}$$

$$\pi'(s) = \arg \max_a Q^\pi(s, a)$$

(ج)

سین ارزش کنش $\pi'(s)$ بزرگترین ارزش کنش $\pi(s)$ است

$$\Rightarrow Q^\pi(s, \pi'(s)) \geq V^\pi(s)$$

Q را بازش کنیم

$$\Rightarrow V^\pi(s) \leq E_{\pi'} [R_{t+1} + \gamma V^\pi(s_{t+1}) | s_t = s]$$

$V^\pi(s_{t+1})$ را بازش کنیم

$$V^\pi(s) \leq E_{\pi'} [R_{t+1} + \gamma Q^\pi(s_{t+1}, \pi'(s_{t+1})) | s_t = s]$$

$$\Rightarrow V^\pi(s) \leq E_{\pi'} [R_{t+1} + \gamma R_{t+2} + \gamma^2 V^\pi(s_{t+2}) | s_t = s]$$

اگر γ ها را تا آخر باز کنیم به فرمول $V^{\pi'}(s)$ می رسم

$$\Rightarrow V^\pi(s) \leq V^{\pi'}(s)$$

Subject:

Date:

$$\forall s \in S \quad V^{\pi}(s) = V^{\pi'}(s)$$

بخش دوم

$$V^{\pi'}(s) = \max_a Q^{\pi'}(s, a)$$

$$\Rightarrow V^{\pi'}(s) = \max_a \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V^{\pi'}(s'))$$

این همان معادله بلوم است که در آن π^* همان π باشد

بهینه است

DAT

States $\Rightarrow S = \{(0, C), (1, C), (2, C), (3, C), (4, C), (5, C), \text{Done}\}$ (الف - د)

یا $n > 5$ یا $n \leq 5$ stop انتخاب شود

$$R((n, C), \text{stop}, \text{Done}) = n$$

$$R((n, C), \text{draw}, (n', C)) = 0 \quad n' \leq 5$$

$$R((n, C), \text{draw}, \text{Done}) = 0$$

$$V_{k+1}(s) = \max_a \sum_s T(s, a, s') (R(s, a, s') + \gamma V_k(s'))$$

$$V_0(s') = 0 \quad \text{و} \quad V_k(\text{Done}) = 0$$

$$\forall s' \in S \quad \forall k \in [0, \infty)$$

مرحله اول:

$$V_1((0, C)) = a = \text{stop} \Rightarrow 0$$

$$a = \text{draw} \Rightarrow \frac{1}{2}(0) + \frac{1}{2}(0) + \frac{1}{2}(0) = 0$$

$$\Rightarrow V_1((0, C)) = 0 = Q_1((0, C), \text{stop}) \quad \text{و} \quad Q_1((0, C), \text{draw}) = 0$$

$$V_1((1, C)) = a = \text{stop} \Rightarrow 1$$

$$a = \text{draw} \Rightarrow 0$$

$$\Rightarrow V_1((1, C)) = 1 = Q_1((1, C), \text{stop}) \quad \text{و} \quad Q_1((1, C), \text{draw}) = 0$$

DAT

$$V_1((3, C)) = \begin{array}{l} a = \text{stop} \Rightarrow 3 \\ a = \text{draw} \Rightarrow 0 \end{array}$$

$$\Rightarrow V_1((3, C)) = 3 = Q_1((3, C), \text{stop}) \text{ و } Q_1((3, C), \text{draw}) = 0$$

$$V_1((2, C)) = \begin{array}{l} a = \text{stop} \Rightarrow 2 \\ a = \text{draw} \Rightarrow 0 \end{array}$$

$$\Rightarrow V_1((2, C)) = 2 = Q_1((2, C), \text{stop}) \text{ و } Q_1((2, C), \text{draw}) = 0$$

$$V_1((0, C)) = \begin{array}{l} a = \text{stop} \Rightarrow 0 \\ a = \text{draw} \Rightarrow 0 \end{array}$$

$$V_1((0, C)) = 0 = Q_1((0, C), \text{draw}) = Q_1((0, C), \text{draw})$$

مرحله دوم: استیت های $(4, C)$ و $(5, C)$ همواره ارزش $(0, C)$ را خواهند داشت

و اکشن stop نخواهد بود پس برای $(3, C)$ و $(2, C)$ و $(0, C)$

ادامه می دهیم

$$V_2((3, C)) = \begin{array}{l} a = \text{stop} \Rightarrow 3 \\ a = \text{draw} \Rightarrow \frac{1}{3}(0 + 5) + \frac{1}{3}(0) + \frac{1}{3}(0) = \frac{5}{3} \end{array}$$

$$\Rightarrow V_2((3, C)) = 3 = Q_2((3, C), \text{stop}) \text{ و } Q_2((3, C), \text{draw}) = \frac{5}{3}$$

$$V_2((1, C)) = a = \text{stop} \Rightarrow 2$$

$$a = \text{draw} \Rightarrow \frac{1}{3}(0+4) + \frac{1}{3}(0+2) + \frac{1}{3}(0) = 2$$

$$\Rightarrow V_2((1, C)) = 2 = Q_2((1, C), \text{draw}) \text{ و } Q_2((1, C), \text{stop}) = 2$$

$$V_2((0, C)) = a = \text{stop} \Rightarrow 0$$

$$a = \text{draw} \Rightarrow \frac{1}{3}(0+2) + \frac{1}{3}(0+3) + \frac{1}{3}(0+4) = 3$$

$$\Rightarrow V_2((0, C)) = 3 = Q_2((0, C), \text{draw}) \text{ و } Q_2((0, C), \text{stop}) = 0$$

مرحله سوم: (از 0 و 2) تا (5 و 0) تفسیر می‌کنند:

$$V_2((0, C)) = a = \text{stop} \Rightarrow 0$$

$$a = \text{draw} \Rightarrow \frac{1}{3}(0+3) + \frac{1}{3}(0+3) + \frac{1}{3}(0+4) = \frac{10}{3}$$

$$V_2((0, C)) = \frac{10}{3} = Q_2((0, C), \text{draw}) \text{ و } Q_2((0, C), \text{stop}) = 0$$

مرحله چهارم: می‌توانیم از استیت‌ها 0 و 2 نشان تفسیر می‌کنیم

$$V^*((5, C)) = 5, V^*((4, C)) = 4, V^*((3, C)) = 3$$

$$V^*((2, C)) = 3, V^*((0, C)) = \frac{10}{3} \text{ و } \pi^*((5, C)) = \text{stop}$$

$$\pi^*((4, C)) = \text{stop} \text{ و } \pi^*((3, C)) = \text{stop} \text{ و } \pi^*((2, C)) = \text{draw}$$

DAT

$$\text{و } \pi^*((0, C)) = \text{draw}$$

چون فقط کارت ۲ در مایه پس / حالت های (۳، ۰) و (۰، ۰) و (۰، ۰)

۰ طول خود را دارند (از ۰ و ۰) شروع می شود بازی

$$Q_1((0,0), \text{stop}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

$$Q_2((0,0), \text{stop}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

$$Q_3((0,0), \text{stop}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

چون تعداد زیادی همپل داریم حدنهایی به ۰ می رسد

$$Q_1((0,1), \text{stop}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

$$Q_2((0,1), \text{stop}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

حدنهایی این نیز ۰ است

حدنهایی $Q((0,0), \text{stop})$ هم بدینها صفر است

$$Q_1((0,0), \text{draw}) = \frac{1}{2}(0) + \frac{1}{2}(0+0) = 0$$

همواره صفر خواهد بود

$$Q_1((1, C), \text{draw}) = \frac{1}{2}(0) + \frac{1}{2}(0+4) = 2$$

$$Q_2((1, C), \text{draw}) = \frac{1}{2}(2) + \frac{1}{2}(0+4) = 3$$

در نهایت این هم 4 است

$$Q_1((0, C), \text{draw}) = \frac{1}{2}(0) + \frac{1}{2}(0+4) = 2$$

$$Q_2((0, C), \text{draw}) = \frac{1}{2}(2) + \frac{1}{2}(0+4) = 3$$

$$Q_3((0, C), \text{draw}) = \frac{1}{2}(3) + \frac{1}{2}(0+4) = 3.5$$

در نهایت این هم 4 است

$$(0, C) = \text{stop} \Rightarrow 0 \quad \text{draw} \Rightarrow 4$$

$$(1, C) = \text{stop} \Rightarrow 2 \quad \text{draw} \Rightarrow 4$$

$$(2, C) = \text{stop} \Rightarrow 0 \quad \text{draw} \Rightarrow 0$$

$$(4, C) = \text{stop} \Rightarrow 4 \quad \text{draw} \Rightarrow 0$$

$$(2, C) = \text{stop} \Rightarrow 0 \quad \text{draw} \Rightarrow 0$$

DAT

$$\epsilon\text{-greedy} \Rightarrow a_t = \begin{cases} \text{random action} & \text{به احتمال } \epsilon \\ \arg \max_a Q(s_t, a) & 1 - \epsilon \end{cases}$$

با احتمال $0/4 = 0/2$ اکشن stop را انتخاب می‌کنیم چون

$$Q((\epsilon, C), \text{stop}) = 4 > 3 = Q((\epsilon, C), \text{draw})$$

و با احتمال $0/4$ به صورت رندوم $\Leftarrow$
 $\text{stop} \Rightarrow 0/4 = 0/2 \quad \text{draw} \Rightarrow 0/4 = 0/2$

پس در کل با احتمال $0/1$ stop و $0/2$ draw

طبق بخش ج داریم:

$$Q((\epsilon, C), \text{stop}) = 4 \quad Q((\epsilon, C), \text{draw}) = 0$$

$$\Rightarrow E[Q] = 0/1 \times 4 + 0/2 \times 0 = 3/2$$

(ب) توجہ بہ مقدار بخش جہ داریم:

$$\text{regret}_1 = V^*(1, c) - Q^*(1, c, \text{draw}) = \frac{1}{3} - \frac{1}{3} = 0$$

$$\text{regret}_2 = V^*(1, c) - Q^*(1, c, \text{stop}) = 3 - 2 = 1$$

$$\text{regret}_3 = V^*(1, c) - Q^*(1, c, \text{draw}) = \frac{1}{3} - \frac{1}{3} = 0$$

$$\text{regret}_4 = V^*(4, c) - Q^*(4, c, \text{draw}) = 4 - 0 = 4$$

$$\Rightarrow \text{regret} = \sum_{t=1}^4 \text{regret}_t = 0 + 1 + 0 + 4 = 5$$

Subject:

Date:

$$Q^*((\omega, c), \text{stop}) = \omega \quad Q^*((\omega, c), \text{draw}) = 0$$

$$Q^*((\xi, c), \text{stop}) = \xi \quad Q^*((\xi, c), \text{draw}) = 0$$

$$Q^*((\gamma, c), \text{stop}) = \gamma \quad Q^*((\gamma, c), \text{draw}) = \frac{\omega}{\gamma}$$

$$Q^*((\gamma, c), \text{stop}) = \gamma \quad Q^*((\gamma, c), \text{draw}) = \gamma$$

$$Q^*((\omega, c), \text{stop}) = 0 \quad Q^*((\omega, c), \text{draw}) = \frac{1}{\gamma}$$

DAT

Subject:

Date:

$$T(X, a, Y) = \frac{2}{3} \quad T(X, a, Z) = \frac{1}{3}$$

خالف

$$T(X, b, X) = 1$$

برای سایر حالات $T=0$

$$T(Y, a, Z) = \frac{2}{3} \quad T(Y, a, Y) = \frac{1}{3}$$

$$T(Y, b, X) = 1$$

$$T(Z, a, Z) = 1 \quad T(Z, b, X) = 1$$

$$R(X, a, Y) = R(X, a, Z) = 3$$

بیم

برای سایر حالات $R=0$

$$R(X, b, X) = 1$$

$$R(Y, a, Z) = R(Y, a, Y) = 4$$

$$R(Y, b, X) = 2$$

$$R(Z, a, Z) = 0 \quad R(Z, b, X) = 5$$

DAT

Subject:

Date:

$$V_{k+1}(s) = \max_a \sum_{s'} T(s, a, s') (R(s, a, s') + \gamma V_k(s')) \quad (2)$$

$$V_1(X) = a \Rightarrow \frac{\gamma}{1-\gamma} (\gamma + 0) + \frac{1}{1-\gamma} (\gamma + 0) = \gamma$$

$$b \Rightarrow 1(1+0) = 1$$

$$V_1(X) = \gamma \quad \pi(X) = a \quad Q_1(X, a) = \gamma \quad Q_1(X, b) = 1$$

$$V_1(Y) = a \Rightarrow \frac{\gamma}{1-\gamma} (\xi + 0) + \frac{1}{1-\gamma} (\xi + 0) = \xi$$

$$b \Rightarrow 1(\gamma + 0) = \gamma$$

$$V_1(Y) = \xi \quad \pi(Y) = a \quad Q_1(Y, a) = \xi \quad Q_1(Y, b) = \gamma$$

$$V_1(Z) = a \Rightarrow 1(0 + 0) = 0$$

$$b \Rightarrow 1(\omega + 0) = \omega$$

$$V_1(Z) = \omega \quad \pi(Z) = b \quad Q_1(Z, a) = 0 \quad Q_1(Z, b) = \omega$$

$$\Rightarrow V_1(X) = \gamma, V_1(Y) = \xi, V_1(Z) = \omega$$

$$\pi(X) = a \quad \pi(Y) = a \quad \pi(Z) = b$$

DAT

(د) به همگرایی تعیین شده است یعنی که هر دفعه عدد $0/9$ در $V_k(z)$ ضرب

همیشه که در مرحله اول صفر بعد 0 بعد $0/9 \times 0$ بعد $0/9 \times 0$ بعد $0/9 \times 0$ بعد $0/9 \times 0$

همینطور تا $0/9 \times 0$ که برای n های بزرگ $V(z)$ به صفر میل می کند

$$V_{n+1}(z) = 1 \times (0 + (0/9)^n \times 0) \rightarrow 0$$