



هوش مصنوعی

بهار ۱۴۰۵

استاد: ماری اوریاد

گردآوردندگان: یاسمین رجبی، کیارش صانعی، امیرپارسا صفری،
علی منصوریان، آرش نظری منش، علی نوری

مهلت ارسال: ۱۵ تیر

یادگیری تقویتی

تمرین پنجم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- در طول ترم امکان ارسال با تاخیر پاسخ همه‌ی تمارین تا سقف ۴ روز و در مجموع ۱۰ روز، وجود دارد. پس از گذشت این مدت، پاسخ‌های ارسال‌شده پذیرفته نخواهند بود. همچنین، به ازای هر ساعت تأخیر غیر مجاز ۰.۵ درصد از نمره تمرین به صورت ساعتی کسر خواهد شد.
- هم‌کاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتماً باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفاً تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.
- پاسخنامه سوالات را در سامانه کوئرا و به فرمت `AI_HW5_<STUDENT_ID>` بارگزاری کنید.

سوالات نظری (۱۰۰ نمره)

۱. (۱۵ نمره) با ذکر دلیل، درست و غلط بودن گزاره‌های زیر را مشخص نمایید.
 - (آ) در الگوریتم Value Iteration، نرخ همگرایی به سیاست بهینه π^* معمولاً سریع‌تر از نرخ همگرایی خود تابع ارزش V^* است؛ به این معنا که ممکن است سیاست بهینه قبل از اینکه تابع ارزش به مقدار دقیق خود برسد، ثابت شود.
 - (ب) Q-learning تنها زمانی مقادیر بهینه Q-values را یاد می‌گیرد که کنش‌هایی (actions) که در نهایت انتخاب می‌شود، بر اساس سیاست (policy) بهینه باشد.
 - (ج) اگر بدانیم که $|A| \approx |S|$ آنگاه پیچیدگی زمانی اجرای هر ایتريشن در policy iteration و value iteration تقریباً با هم برابر می‌شود.
 - (د) در یک MDP با حالات محدود و پاداش با باند مشخص و $\gamma < 1$ ، در صورتی که همه پاداش‌ها با عدد ثابت c جمع شود، سیاست بهینه تغییر نمی‌کند.
 - (ه) اگر تنها تفاوت بین دو فرآیند تصمیم‌گیری مارکوف (MDP) مقدار ضریب تخفیف باشد، آنگاه این دو حتماً سیاست بهینه‌ی یکسانی دارند.
 - (و) در یک MDP با افق محدود (finite horizon) به طول T ، سیاست بهینه‌ی $\pi^*(s)$ ممکن است بسته به تعداد گام‌های باقی‌مانده تغییر کند؛ به این معنا که حتی برای یک حالت یکسان s نیز، سیاست بهینه می‌تواند ناپایستا (non-stationary) باشد.
- در مورد سوالات زیر توضیح مختصر و کوتاه دهید.

(آ) تفاوت on-policy RL و off-policy RL چیست؟

(ب) تفاوت model-based RL و model-free RL چیست؟

۲. (۱۸ نمره) در شکل زیر یک محرک قرار دارد که همواره از خانه‌ی (۱، ۱) که با S نشان داده شده است، شروع به حرکت می‌کند. خانه‌ها را با زوج (سطر، ستون) نشان می‌دهیم. دو تا از خانه‌های جدول، خانه‌های پایانی هستند: خانه‌ی (۳، ۲) با جایزه‌ی $+10$ و خانه‌ی (۳، ۱) با جایزه‌ی -10 . در خانه‌هایی که پایانی نیستند، جایزه‌ای وجود ندارد. (جایزه‌ی یک خانه در صورتی دریافت می‌شود که محرک به آن خانه وارد شود). تابع احتمال حرکت به این صورت است که برای هر کنش (بالا، پایین، چپ یا راست) با احتمال 0.9 همان حرکت انجام می‌شود و با احتمال 0.05 (برای هر طرف) حرکتی عمود بر جهت در نظر گرفته شده رخ می‌دهد. اگر محرک با دیوار برخورد کند، در همان خانه‌ای که قرار داشته است باقی می‌ماند.

(۱، ۱) S	(۱، ۲)	(۱، ۳)
(۲، ۱)	(۲، ۲)	(۲، ۳)
		$+10$



(آ) فرض کنید محرک احتمال‌های مربوط به حرکت‌ها را می‌داند. دو مرحله‌ی اولیه‌ی الگوریتم Value Iteration را برای هر وضعیت (خانه) انجام دهید. $\gamma = 0.9$ و $V_0 = 0$ را برای هر وضعیتی در نظر بگیرید.

(ب) با استفاده از $\alpha = 0.1$ و مقدارهای اولیه‌ی صفر، آپدیت‌های Temporal-Difference Learning را بعد از تجربه‌ی

$$(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$$

و

$$(1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow (2, 3)$$

برای $V(s)$ ها بنویسید ($\gamma = 0.9$). (توجه داشته باشید که در هر یک از مسیرهای گفته شده، کنش انتخاب شده‌ی محرک در هر گام «راست» بوده است؛ پس در مسیر دوم، رفتن از (۱، ۲) به (۲، ۲) نتیجه‌ی همان اشتباه شانس در نتیجه حرکت است.)

(ج) همان‌طور که در بخش قبل گفته شد، کنش انتخاب شده در هر گام هر دو مسیر «راست» است. برای هر مسیر آپدیت‌های مقدار Q را با روش SARSA (در حالت on-policy) و با $Q_0(s, a) = 0$ و $\alpha = 0.1$ و $\gamma = 0.9$ محاسبه کنید.

(د) همان آپدیت‌ها را این بار با Q-learning (در حالت off-policy) دوباره حساب کنید و دو روش را مقایسه نمایید. گامی را که در آن این دو الگوریتم آپدیت متفاوتی تولید می‌کنند مشخص کنید و در یک جمله توضیح دهید چرا آن گام متفاوت بوده است.

(ه) با استفاده از همان دو مسیر بخش ۲ و $\gamma = 0.9$ ، برای هر حالتی که در این دو مسیر دیده شده است، تخمین ارزیابی مستقیم (Direct Evaluation) از $V^\pi(s)$ را با میانگین‌گیری از بازده‌های تخفیف خورده‌ی مشاهده شده از آن حالت به بعد محاسبه کنید. کدام حالت‌ها هنوز هیچ تخمینی ندارند؟ این موضوع چه ارتباطی به sample efficiency ارزیابی مستقیم در مقابل TD دارد؟

۳. (۱۵ نمره)


در یک MDP دو سیاست π_1 و π_2 با توابع ارزش V_1 و V_2 داریم. سیاست جدید π_3 که به صورت

$$\pi_3 = \frac{1}{4}\pi_1 + \frac{1}{4}\pi_2$$

تعریف می‌شود به این صورت است که در هر گام به احتمال یک دوم مطابق π_1 و به احتمال یک دوم مطابق π_2 عمل می‌کند. تابع ارزش این سیاست را V_3 می‌نامیم. آیا می‌توان گفت $V_3 = \frac{1}{4}V_1 + \frac{1}{4}V_2$ است؟ اثبات کنید یا مثال نقض بیاورید.

۴. (۱۸ نمره)

فرآیند تصمیم‌گیری مارکوف (MDP) که در شکل زیر آمده است را با ضریب تخفیف $\gamma = 0.5$ در نظر بگیرید که در آن حالت‌ها با حروف A ، B و C نشان داده شده‌اند. روی هر یال یک حرف کوچک نوشته شده که یکی از کنش‌های موجود است و یال مربوطه گذار متناظر با انجام آن کنش را نشان می‌دهد. عدد صحیح روی هر یال نیز پاداش کسب‌شده از آن کنش است. تمام گذرها با احتمال ۱ به وقوع می‌پیوندند و تنها گذار از حالت C با کنش x تصادفی است: با انجام کنش x در حالت C پاداش ۸ دریافت می‌شود و محرک با احتمال $\frac{1}{4}$ به حالت A می‌رود و با احتمال $\frac{3}{4}$ در حالت C باقی می‌ماند.



شکل ۱: گراف فرآیند تصمیم‌گیری مارکوف.

با در نظر گرفتن این فرآیند، به سؤالات زیر پاسخ دهید.

(آ) سیاست اولیه π_1 را در نظر بگیرید که به صورت تصادفی و با احتمال برابر در هر حالت یکی از کنش‌های موجود در آن حالت را انتخاب می‌کند. حال فرض کنید تابع ارزش حالت‌های اولیه را به صورت $V_1(A) = 2$ ، $V_1(B) = V_1(C) = 2$ در نظر بگیریم. یک مرحله از الگوریتم ارزیابی سیاست π_1 را اجرا کنید تا به تابع ارزش‌گذاری جدید برای حالت‌ها برسید.

(ب) بر اساس تابع ارزش‌گذاری جدید و به صورت حریصانه، سیاست قطعی جدید π_2 را به دست آورید.

(ج) سیاست قطعی π را در نظر بگیرید. اثبات کنید اگر سیاست جدید π' به صورت حریصانه از V^π به دست آمده باشد، آنگاه سیاست π' بهتر یا مساوی π است، یا به عبارتی برای تمام حالت‌ها داریم $V^{\pi'}(s) \geq V^\pi(s)$. هم چنین اثبات کنید اگر تساوی برای تمام حالت‌ها رخ دهد آنگاه π' حتماً سیاست بهینه است.

۵. (۱۷ نمره) در بازی micro - blackjack در هر مرحله از دسته کارت موجود یک کارت را بیرون می‌کشید و سپس دوباره آن را برمی‌گردانید و برمی‌زنید. کارت بیرون کشیده شده همیشه با احتمال برابر، مساوی یک از ۳ عدد ۲ و ۳ و ۴ است. اگر جمع اعداد کارت‌های بیرون کشیده شده کمتر از ۶ بود، می‌توانید باز هم به بازی ادامه دهید و یا اینکه متوقف شوید. اما اگر جمع این اعداد بیشتر از ۵ بود بازی به اتمام می‌رسد و دیگر نمی‌توانید کارتی بیرون بکشید.

در انتهای بازی امتیاز شما برابر با جمع کارت‌های بیرون کشیده شده است اگر این مقدار کمتر از ۶ باشد و در غیر این صورت برابر ۰ است.

این بازی را به صورت یک MDP با ضریب تخفیف $\gamma = 1$ مدل می‌کنیم. هر حالت را به صورت زوج (n, status) نمایش می‌دهیم که در آن n جمع فعلی کارت‌های بیرون کشیده شده است و status وضعیت بازی

را مشخص می‌کند: مقدار C به این معناست که بازی در جریان است و عامل باید یکی از دو کنش draw (کشیدن یک کارت دیگر) یا stop (توقف) را انتخاب کند، و مقدار Done به این معناست که بازی به پایان رسیده است (حالت پایانی). در آغاز بازی در حالت $(0, C)$ قرار داریم. هرگاه عامل کنش stop را انتخاب کند یا با کشیدن کارت جمع کارت‌ها از ۵ بیشتر شود، به حالت پایانی Done می‌رویم و بازی تمام می‌شود.

(آ) با استفاده از این مدل‌سازی، فضای حالت این بازی چیست؟

(ب) تابع reward در این مسئله به چه شکل است؟

(ج) با استفاده از الگوریتم Value Iteration مقدار بهینه هر state و همچنین policy بهینه را پیدا کنید.

(د) فرض کنید به جای پیدا کردن این مقادیر به صورت offline بخواهیم از Q-Learning استفاده کنیم. فرض کنید به مقدار بسیار زیادی بازی انجام داده‌اید و تعداد بسیار زیادی سمپل دارید. ولی به طرز عجیبی در همه‌ی این سمپل‌ها، هر بار که کارتی بیرون کشیده‌اید، مقدار روی آن برابر با ۲ بوده است. حد نهایی توابع Q در صورتی که مقدار اولیه آن‌ها ۰ و learning rate برابر با $\frac{1}{4}$ باشد چقدر است؟

(ه) مقادیر بهینه‌ی V^* و Q^* به دست آمده در بخش ۳ را به عنوان مقادیر درست (ground truth) در نظر بگیرید. حالت $s = (4, C)$ را در نظر بگیرید که در آن مقادیر یادگرفته شده‌ی فعلی به صورت $Q((4, C), \text{draw}) = 3/0$ و $Q((4, C), \text{stop}) = 4/0$ هستند. تحت سیاست ϵ -greedy با $\epsilon = 0/4$ ، احتمال انتخاب هر کنش و مقدار Q مورد انتظار کنش انتخاب شده را حساب کنید.

(و) regret هر گام را به صورت $\text{regret}_t = V^*(s_t) - Q^*(s_t, a_t)$ تعریف می‌کنیم که در آن a_t کنشی است که واقعاً انجام شده و V^* و Q^* همان مقادیر بخش ۳ هستند. اجرای اکتشافی زیر شامل دو بازی کوتاه است؛ هرگاه به حالت پایانی Done برسیم، بازی از نو در حالت $(0, C)$ آغاز می‌شود. ستون s_{t+1} حالت بعدی (شامل کارت کشیده شده در کنش draw) را نشان می‌دهد. برای این اجرا، regret تجمعی را محاسبه کنید.

t	s_t	a_t	s_{t+1}
۱	$(0, C)$	draw	$(2, C)$
۲	$(2, C)$	stop	Done
۳	$(0, C)$	draw	$(4, C)$
۴	$(4, C)$	draw	Done (bust)

۶. (۱۷ نمره) یک محرک در یک MDP با سه حالت $\{X, Y, Z\}$ و دو کنش $\{a, b\}$ به اکتشاف می‌پردازد. پس از چند اپیزود، چهارتایی‌های مشاهده شده‌ی (s, a, r, s') به صورت زیر ثبت شده‌اند:

s	a	r	s'
X	a	۳	Y
X	a	۳	Y
X	a	۳	Z
X	b	۱	X
X	b	۱	X
Y	a	۴	Z
Y	a	۴	Z
Y	a	۴	Y
Y	b	۲	X
Z	a	۰	Z
Z	a	۰	Z
Z	b	۵	X

(آ) مدل گذار $\hat{T}(s, a, s')$ را برای هر زوج (s, a) با شمارش و نرمال‌سازی تخمین بزنید.

- (ب) مدل پاداش $\hat{R}(s, a, s')$ را از روی پاداش‌های مشاهده‌شده تخمین بزنید.
- (ج) با استفاده از $\gamma = 0.9$ و مدل‌های تخمینی $\hat{R}$ و $\hat{T}$ ، یک مرحله از به‌روزرسانی Value Iteration را از $V_0 = 0$ انجام دهید تا V_1 برای هر حالت به‌دست آید، و سپس کنش حریصانه‌ی هر حالت را مشخص کنید.
- (د) تحت کنش a ، حالت Z یک حالت absorbing است ($\hat{T}(Z, a, Z) = 1$ و $R = 0$). آیا همگرایی Value Iteration روی این MDP یادگرفته‌شده تضمین‌شده است؟ در یک جمله توضیح دهید.