

(الف) درست

هرچه قدر مدل پیچیده تر باشد می تواند ریز ترین جزئیات داده تست را بفهمد و احتمال $overfitting$ بیشتر می شود تا حدی که به جای یادگیری الگوی کلی، نویزها را نیز یاد می گیرد

(ب) نادرست

با افزایش تعداد مدل می تواند به توزیع واقعی تری از داده تست را یاد بگیرد و $generalization$ آن بالا می رود که احتمال $overfitting$ را کاهش می دهد

(ج) نادرست

$$P_{LAP, k}(x) = \frac{C(x) + k}{N + k|X|}$$

طبق فرمول رویه رو، هر چه k بیشتر شود، به سمت

توزیع $uniform$ می روییم که این احتمال $underfitting$ را زیاد می کند

(د) درست

وقتی محقق در پشت زیاد می شود، می تواند جزئیات ریز داده تست را حفظ کند و احتمال $overfitting$ بیشتر می شود

DAT

(۴) نادرست

با عبارت Regularization را اضافه می کنیم تا از over fitting جلوگیری

شود این اضافه کردن باعث می شود مدل پیچیدگی ها را سرس نکند و ساده تر بماند

(۵) نادرست

وقتی ضریب گام بزرگ است ممکن است محلی به local minima فرسود و اگر

شود. اگر ضریب گام کوچک بود احتمال over fitting بیشتر می شد

$$IG(X_0) = H(Y) - H(Y|X_0)$$

A	B
$Y_0 + \omega + 1 = 35$	$\omega + 1 + 1 = 30$

(۶) الف

$$H(Y) = (p(A) \log_2 p(A) + p(B) \log_2 p(B))$$

$$\Rightarrow -\left(\frac{35}{65} \log_2 \frac{35}{65} + \frac{30}{65} \log_2 \frac{30}{65}\right) = 0.91 + 0.515 = 0.995$$

$$H(Y|X_0) = \left(\frac{35}{65} \left(\frac{20}{35} \log_2 \frac{20}{35} + \frac{15}{35} \log_2 \frac{15}{35}\right) + \frac{30}{65} \left(\frac{15}{30} \log_2 \frac{15}{30} + \frac{15}{30} \log_2 \frac{15}{30}\right)\right)$$

$$= \left(\frac{35}{65} \times 0.722 + \frac{30}{65} \times 0.918\right) = 0.845$$

$$IG(X_0) = 0.995 - 0.845 = 0.15$$

DAT

(ب) در گره ۲ A در ۳ B و در ۴ نیز B انتخاب می شود (به دلیل اکثریت)

در گره ۲، ۲۰ در گره ۳، ۱۵ و در گره ۴، ۱۰ مورد بیش بین درست داریم

$$\Rightarrow \frac{20 + 15 + 10}{45} \times 100 = 49.23\% \quad \left(\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \right)$$

$$\text{BCE} \Rightarrow J(w) = - \sum_{i=1}^n (y^{(i)} \log(\sigma(z)) + (1 - y^{(i)}) \log(1 - \sigma(z))) \quad \text{نیم الف}$$

$$\sigma(z) = \hat{y}^{(i)}$$

یا نزدیک

اگر مقدار واقعی یک باشد ($y^{(i)} = 1$) و یک را بیش بین کمتر خطا صفر می شود

یا نزدیک صفر

و اگر صفر را بیش بین کمتر خطا بینهایت می شود

یا نزدیک

اگر مقدار واقعی صفر باشد ($y^{(i)} = 0$) و یک را بیش بین کمتر خطا بینهایت

می شود و اگر صفر را بیش بین کمتر خطا صفر می شود

یا نزدیک صفر

و این تابع محدب نیز است پس با gradient descent می توان به

global minima رسید

Subject:

Date:

$$\frac{\partial J}{\partial \sigma} = - \sum_{i=1}^n \left(\frac{y^{(i)}}{\sigma(z)} - \frac{1-y^{(i)}}{1-\sigma(z)} \right)$$

(-) مبنای log را e می گیریم

$$\frac{\partial \sigma}{\partial z} = - \frac{-e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \left(1 - \frac{1}{1+e^{-z}} \right) = \sigma(z)(1-\sigma(z))$$

$$\frac{\partial z}{\partial w_j} = x_j$$

$$\Rightarrow \frac{\partial J}{\partial w_j} = - \sum_{i=1}^n \left(\frac{y^{(i)}(1-\sigma(z)) - \sigma(z)(1-y^{(i)})}{\sigma(z)(1-\sigma(z))} \right) \times \cancel{\sigma(z)} \times \cancel{(1-\sigma(z))} \times x_j^{(i)}$$

$$\Rightarrow \frac{\partial J}{\partial w_j} = - \sum_{i=1}^n (y^{(i)} - \sigma(z)) x_j^{(i)}$$

$$z = w_0 x_0 + \dots + w_d x_d$$

$$\Rightarrow \frac{\partial J}{\partial w_j} = \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$

DAT