



نه تو می‌مانی، نه اندوه، و نه هیچ یک از مردم این آبادی
به حباب نگران لب یک رود قسم، و به کوتاهی آن لحظه‌ی شادی که گذشت
غصه هم خواهد رفت، آن‌چنانی که فقط خاطره‌ای خواهد ماند
لحظه‌ها عریانند، به تن لحظه‌ی خود جامه‌ی اندوه می‌پوشان هرگز
«سهراب سپهری»

۱. (۲۰ نمره) در رابطه با شبکه‌های عصبی CNN و Transformer، به سوالات زیر پاسخ مختصر و مستدل دهید.

- (آ) در یک لایه‌ی کانولوشنی، ابعاد ورودی $3 \times 64 \times 64$ می‌باشد. این لایه شامل ۶ کرنل (فیلتر)، هر کدام به ابعاد $3 \times 5 \times 5$ است. با فرض آنکه از ۲ لایه Padding استفاده شده باشد و مقدار جهش (Stride) برابر با ۳ باشد، ابعاد خروجی این لایه چقدر است؟
- (ب) مهم‌ترین دلیل استفاده از لایه‌ی Pooling در شبکه‌های کانولوشنی چیست؟
- (ج) دو مورد از مهم‌ترین مشکلات شبکه‌های عصبی Fully Connected معمولی برای مدل‌سازی زبانی و استفاده روی توالی کلمات را بیان نمایید.
- (د) فرض کنید در یک لایه‌ی ترنسفورمر (مکانیزم توجه)، ابعاد ورودی (X) برابر با $N \times D$ می‌باشد که N تعداد توکن‌های ورودی و D بعد ویژگی‌های هر توکن می‌باشد. این لایه‌ی ترنسفورمر حداقل چه تعداد پارامتر قابل یادگیری دارد؟

حل.

(آ) رابطه‌ی محاسبه‌ی ابعاد خروجی (طول و عرض) در یک لایه‌ی کانولوشنی به صورت زیر است:

$$O = \left\lfloor \frac{W - F + 2P}{S} \right\rfloor + 1$$

که در آن W بعد ورودی (64)، F اندازه فیلتر (5)، P میزان Padding (2) و S مقدار گام یا Stride (۳) است.

با جایگذاری مقادیر، برای طول (و عرض) خروجی داریم:

$$O = \left\lfloor \frac{64 - 5 + 2(2)}{3} \right\rfloor + 1 = \left\lfloor \frac{63}{3} \right\rfloor + 1 = 21 + 1 = 22$$

از آنجایی که تعداد فیلترها (کرنل‌ها) در این لایه برابر با ۶ است، عمق یا تعداد کانال‌های خروجی نیز برابر ۶ خواهد بود. بنابراین ابعاد خروجی برابر است با:

$$22 \times 22 \times 6$$

(ب) مهم‌ترین دلیل استفاده از این لایه در شبکه‌های کانولوشنی کاهش ابعاد و بار محاسباتی می‌باشد. با کاهش اندازه‌ی نقشه‌های ویژگی (Feature Maps)، تعداد پارامترهای لایه‌های Fully Connected انتهایی شبکه به شدت کاهش می‌یابد که این امر باعث افزایش سرعت پردازش و کاهش خطر بیش‌برازش (Overfitting) می‌شود.

(ج) دو مشکل اساسی این شبکه‌ها برای پردازش توالی‌ها عبارتند از:

- عدم پشتیبانی از ورودی‌هایی با طول متغیر: شبکه‌های FC نیازمند ورودی‌هایی با ابعاد کاملاً ثابت هستند. در حالی که در کاربردهای پردازش زبان طبیعی (NLP)، طول جملات متغیر است و استفاده از تکنیک‌هایی مانند Padding برای یکسان‌سازی طول، بسیار ناکارآمد است.
- عدم امکان کار با کلمات: به طور کلی شبکه‌های عصبی با اعداد (بردارها و ماتریس‌ها) سر و کله می‌زنند، نه با کلمات و جملات. در واقع یک شبکه‌ی عصبی معمولی درکی از کلمه (توالی حروف) ندارد و ابتدا لازم هست کلمات را به بردارهایی از اعداد تبدیل نماییم. این عمل معمولاً از طریق One-hot Encoding و لایه‌ی Word Embedding انجام می‌گردد.

(د) طبق صورت سوال، در این لایه ما سه ماتریس وزن (Weight Matrix) برای تبدیل ورودی به K ، Q و V داریم:

- ماتریس W_Q به ابعاد $D \times D \leftarrow$ تعداد پارامترها: D^2
- ماتریس W_K به ابعاد $D \times D \leftarrow$ تعداد پارامترها: D^2
- ماتریس W_V به ابعاد $D \times D \leftarrow$ تعداد پارامترها: D^2

بنابراین (Bias)، این لایه حداقل $3D^2$ پارامتر قابل یادگیری دارد. نکته‌ی مهم آن است که تعداد پارامترها مستقل از تعداد توکن‌های ورودی (N) می‌باشد.

۲. (۵۰ نمره) با رسم دقیق ساختار شبکه (ارتباط نورون‌ها)، مشخص نمودن وزن‌ها و بایاس‌ها و تابع فعال‌سازی برای هر نورون، شبکه‌ای عصبی طراحی کنید که تابع سه متغیره $f(x_1, x_2, x_3) = 3x_1x_2 - 5x_3^2$ را با حداکثر دو لایه و حداکثر چهار نورون به طور دقیق مدل کند. آیا می‌توان این تابع را با تعداد کمتری نورون مدل کرد؟ حل.

برای طراحی شبکه‌ای که بتواند توابع غیرخطی شامل ضرب متغیرها را مدل کند، می‌توانیم از تابع فعال‌سازی مربع (توان دوم) استفاده کنیم: $\sigma(z) = z^2$. دلیل این انتخاب، امکان استفاده از اتحاد جبری مشهور برای تولید جمله‌ی ضربی x_1x_2 از ترکیبات خطی است:

$$x_1x_2 = \frac{1}{4} \left((x_1 + x_2)^2 - (x_1 - x_2)^2 \right)$$

با استفاده از این اتحاد، تابع هدف به شکل ترکیبی خطی از مربعات تبدیل می‌شود:

$$f(x_1, x_2, x_3) = 3 \left[\frac{1}{4}(x_1 + x_2)^2 - \frac{1}{4}(x_1 - x_2)^2 \right] - 5x_3^2$$

$$f(x_1, x_2, x_3) = 0.75(x_1 + x_2)^2 - 0.75(x_1 - x_2)^2 - 5x_3^2$$

ساختار شبکه (مجموعاً ۲ لایه و ۴ نورون):

- لایه‌ی اول (لایه‌ی پنهان - شامل ۳ نورون):

- نورون h_1 : وزن‌ها: $w_{11} = 1, w_{12} = 1, w_{13} = 0$ | بایاس: $b_1 = 0$ | تابع فعال‌سازی:

$$\sigma(z) = z^2$$

$$\Leftarrow \text{خروجی نورون اول: } h_1 = (x_1 + x_2)^2$$

- نورون h_2 : وزن‌ها: $w_{21} = 1, w_{22} = -1, w_{23} = 0$ | بایاس: $b_2 = 0$ | تابع فعال‌سازی:

$$\sigma(z) = z^2$$

$$\Leftarrow \text{خروجی نورون دوم: } h_2 = (x_1 - x_2)^2$$

- نورون h_3 : وزن‌ها: $w_{31} = 0, w_{32} = 0, w_{33} = 1$ | بایاس: $b_3 = 0$ | تابع فعال‌سازی:

$$\sigma(z) = z^2$$

$$\Leftarrow \text{خروجی نورون سوم: } h_3 = x_3^2$$

• لایه‌ی دوم (لایه‌ی خروجی - شامل ۱ نورون):

- نورون خروجی y : وزن‌ها: $v_1 = 0.75, v_2 = -0.75, v_3 = -5$ | بایاس: $b_{out} = 0$ | تابع

فعال‌سازی: خطی (Identity) یعنی $\sigma(z) = z$

$$\Leftarrow \text{خروجی نهایی شبکه: } y = 0.75h_1 - 0.75h_2 - 5h_3$$

پاسخ سوال بخش دوم (آیا می‌توان این تابع را با تعداد کمتری نورون مدل کرد؟) منفی است.

با بررسی اجزای تابع $x_3^2 = 3x_1x_2 - 5x_3^2 = f(x_1, x_2, x_3)$ داریم:


• بخش x_3^2 : این بخش از دو متغیر دیگر مستقل است. بنابراین برای تولید آن به حداقل ۱ نورون مجزا نیاز داریم که متغیر x_3 را دریافت کرده و به توان دو برساند.

• بخش x_1x_2 : اگر بخواهیم این جمله‌ی ضربی را فقط با یک نورون بسازیم، خروجی آن نورون چیزی شبیه به $(w_1x_1 + w_2x_2)^2$ خواهد بود. اگر این عبارت را بسط دهیم $(w_1^2x_1^2 + w_2^2x_2^2 + 2w_1w_2x_1x_2)$ ، می‌بینیم که علاوه بر جمله‌ی دلخواه ما، عبارات اضافی x_1^2 و x_2^2 نیز تولید می‌شوند.

برای از بین بردن و خنثی کردن این عبارات مزاحم، ما به ناچار به یک نورون دوم هم نیاز داریم تا یک ترکیب متفاوت (مثلاً تفاضل آن‌ها) را به توان دو برساند و در لایه‌ی خروجی با تفریق این دو، جمله‌ی x_1x_2 خالص‌سازی شود. (به همین دلیل در طراحی از دو نورون مجزا برای $(x_1 + x_2)^2$ و $(x_1 - x_2)^2$ استفاده کردیم).

بنابراین، برای استخراج خالص این ویژگی‌ها بدون تولید عبارات اضافی ناخواسته، لایه‌ی پنهان حداقل به $3 = 1 + 2$ نورون نیاز دارد. با در نظر گرفتن ۱ نورون خروجی برای جمع‌بندی خطی نهایی، شبکه‌ی ما در کمترین حالت به ۴ نورون نیاز دارد و با تعداد کمتری نمی‌تواند این تابع را به طور دقیق مدل کند.

۳. (۳۰ نمره) گراف محاسباتی زیر را در نظر بگیرید که در آن g متغیر خروجی و w_1 و w_2 و w_3 متغیرهای ورودی محاسبات می‌باشند. مقدار دقیق عددی $\frac{\partial g}{\partial w_2}$ را با استفاده از قواعد مشتقات زنجیره‌ای محاسبه کنید.



حل.

برای محاسبه‌ی مقدار دقیق $\frac{\partial g}{\partial w_2}$ ، ابتدا مسیر ارتباطی از ورودی w_2 تا خروجی g را در گراف مشخص می‌کنیم. این مسیر به صورت $w_2 \rightarrow e \rightarrow f \rightarrow g$ می‌باشد.

با استفاده از قاعده‌ی مشتق‌گیری زنجیره‌ای (Chain Rule)، گرادیان مورد نظر برابر است با حاصل ضرب مشتقات محلی در این مسیر:

$$\frac{\partial g}{\partial w_2} = \frac{\partial g}{\partial f} \cdot \frac{\partial f}{\partial e} \cdot \frac{\partial e}{\partial w_2}$$

حال مشتقات جزئی هر بخش را با توجه به عملیات گره‌ها و مقادیر محاسبه شده در مسیر پیشرو (Forward Pass) به دست می‌آوریم:

- محاسبه‌ی $\frac{\partial g}{\partial f}$ (گره جمع): رابطه‌ی گره خروجی به صورت $g = f + c$ است. بنابراین مشتق آن نسبت به f برابر است با:

$$\frac{\partial g}{\partial f} = 1$$

- محاسبه‌ی $\frac{\partial f}{\partial e}$ (گره ضرب): رابطه‌ی این گره به صورت $f = a \times e$ است. مشتق آن نسبت به ورودی e برابر با ورودی دیگر یعنی a خواهد بود:

$$\frac{\partial f}{\partial e} = a$$

از روی مقادیر محاسبه شده روی گراف می‌دانیم که $a = 16$ است. بنابراین $\frac{\partial f}{\partial e} = 16$.

- محاسبه‌ی $\frac{\partial e}{\partial w_2}$ (گره فعال‌ساز سیگموئید): گره e نشان‌دهنده‌ی تابع فعال‌سازی سیگموئید (σ) روی ورودی w_2 است. می‌دانیم که مشتق تابع سیگموئید برحسب مقدار خروجی خودش به صورت $\sigma(x)(1 - \sigma(x))$ محاسبه می‌شود:

$$\frac{\partial e}{\partial w_2} = \sigma(w_2)(1 - \sigma(w_2)) = e(1 - e)$$

با توجه به اینکه روی گراف مقدار خروجی این گره $e = 0.95$ داده شده است، با جایگذاری آن داریم:

$$\frac{\partial e}{\partial w_2} = 0.95 \times (1 - 0.95) = 0.95 \times 0.05 = 0.0475$$

در نهایت، با قرار دادن این مقادیر در رابطه‌ی اصلی مشتق زنجیره‌ای، مقدار دقیق گرادیان به دست می‌آید:

$$\frac{\partial g}{\partial w_2} = 1 \times 16 \times 0.0475 = 0.76$$