



آن نخل ناخلف که تبر شد، ز ما نبود
ما را زمانه گر شکند، ساز می‌شویم
«صائب تبریزی»

۱. (۳۰ نمره) درست یا غلط بودن گزاره‌های زیر را با ذکر دلیل کامل مشخص نمایید.

- (آ) اگر یک MDP دارای $|S|$ استیت و $|A|$ اکشن منحصر به فرد باشد، در هر Iteration از الگوریتم Value Iteration، پیچیدگی محاسباتی در حدود $O(|A|^2|S|)$ می‌باشد.
- (ب) اگر یک MDP دارای $|S|$ استیت و $|A|$ اکشن منحصر به فرد باشد، آنگاه حداکثر تعداد گام‌های بهبود سیاست در الگوریتم Policy Iteration برابر با $|S|^{|A|}$ می‌باشد.
- (ج) اگر به همی پاداش‌های یک MDP یک ثابت مثبت c را اضافه کنیم، تابع ارزش بهینه V^* ممکن است تغییر کند اما سیاست بهینه π^* بدون تغییر باقی می‌ماند.

حل.

- (آ) **غلط.** طبق فرمول آپدیت مطرح شده در کلاس، در هر تکرار (Iteration) از الگوریتم Value Iteration، باید مقدار ارزش تمام استیت‌ها (به تعداد $|S|$) به‌روزرسانی شود. برای به‌روزرسانی هر استیت، باید امید ریاضی (Expectation) پاداش‌ها برای تمام اکشن‌های ممکن (به تعداد $|A|$) محاسبه گردد. محاسبه این امید ریاضی (با توجه به احتمالات انتقال) نیازمند جمع زدن روی تمام استیت‌های بعدی (حداکثر به تعداد $|S|$) است. بنابراین پیچیدگی محاسباتی هر تکرار برابر با $O(|A||S|^2) = O(|S| \times |A| \times |S|)$ می‌باشد، نه $O(|A|^2|S|)$.
- (ب) **غلط.** یک سیاست قطعی (Deterministic Policy) تابعی است که به هر استیت دقیقاً یک اکشن اختصاص می‌دهد. از آنجایی که $|S|$ استیت داریم و در هر استیت می‌توان $|A|$ اکشن مستقل انتخاب کرد، کل تعداد سیاست‌های ممکن برابر با $|A|^{|S|}$ است (نه $|S|^{|A|}$). در الگوریتم Policy Iteration، در هر گام بهبود (Policy Improvement) سیاست اکیدا بهتر می‌شود (مگر آنکه به سیاست بهینه رسیده باشیم). از این رو الگوریتم حداکثر پس از بررسی تمام سیاست‌های ممکن، یعنی نهایتاً $|A|^{|S|}$ گام، متوقف خواهد شد.
- (ج) **غلط.** در حالت کلی این گزاره نادرست است. به خصوص در محیط‌هایی با تعدادی Terminal State که باعث می‌شوند لزوماً افق بی‌نهایت نداشته باشیم، مقدار $\gamma = 1$ باشد، و بعد از تعدادی گام محدود، بازی یا آزمایش به پایان برسد. در این حالت، افزودن یک ثابت مثبت c به تمامی پاداش‌ها، باعث می‌شود که مسیرهای طولانی‌تر (با تعداد گام بیشتر) پاداش تجمعی بالاتری نسبت به حالت قبل دریافت کنند. این موضوع می‌تواند منجر به تغییر اولویت مسیرها نسبت به یکدیگر و در نتیجه تغییر سیاست بهینه (π^*) شود.
- فرض کنید در یک استیت (s)، دو انتخاب داریم:

- اکشن A: با انجام این اکشن در استیت s ، بازی در ۱ گام به پایان می‌رسد و پاداش آن ۱۰ است. لذا داریم: $Q^*(s, A) = 10$

- اکشن B: فرض کنید با انجام این اکشن در استیت s ، با احتمال ۱ وارد استیت s' می‌شویم و پاداش ۳ را دریافت می‌کنیم. سپس در s' تنها یک اکشن متعبر داریم که با انجام آن، در یک گام بازی به پایان می‌رسد و پاداش ۵ دریافت می‌شود. لذا به صورت کلی با انجام اکشن B در استیت s بازی به صورت قطعی در ۲ گام به پایان می‌رسد و پاداش تجمعی آن ۸ است. پس داریم: $Q^*(s, B) = 8$

در حالت اولیه، انتخاب اکشن A بهینه است (چون $10 > 8$). حال اگر به هر گام پاداش ثابت $c = 5$ را اضافه کنیم، ارزش‌های جدید عبارتند از:

- ارزش جدید اکشن A در وضعیت s : $10 + 5 = 15$
- ارزش جدید اکشن B در استیت s : $3 + 5 + 5 + 5 = 18$

مشاهده می‌شود که اکنون اکشن B بهینه شده است ($18 > 15$). بنابراین سیاست بهینه تغییر کرده است.

۲. (۲۰ نمره) در یک MDP می‌دانیم که مقادیر پاداش‌ها همواره در بازه‌ی $[a, b]$ قرار دارند. آیا مقدار ارزش بهینه برای تمام استیت‌ها (یعنی $V^*(s)$) نیز لزوماً کران‌دار است؟ اگر پاسخ شما مثبت است، کران $V^*(s)$ را مشخص نمایید و در غیر این صورت، دلیل خود را مطرح کنید.

حله. بله، در صورتی که ضریب تنزیل γ اکیداً کوچک‌تر از ۱ باشد ($\gamma < 1$)، مقدار تابع ارزش بهینه $V^*(s)$ لزوماً کران‌دار است.

اثبات: معادله بهینگی بلمن برای یک MDP با ضریب تنزیل به صورت زیر است:

$$V^*(s) = \max_{a \in A} \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^*(s')]$$

فرض کنیم قدرمطلق بیشینه پاداش برابر با $R_{max} = \max(|a|, |b|)$ باشد، به‌طوری که برای هر پاداش داریم $|R| \leq R_{max}$. با گرفتن قدرمطلق از طرفین معادله داریم:

$$|V^*(s)| = \left| \max_{a \in A} \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^*(s')] \right|$$

با استفاده از نامساوی مثلثی و این واقعیت که $\sum_{s'} P(s'|s, a) = 1$ ، می‌توانیم بنویسیم:

$$|V^*(s)| \leq \max_{a \in A} \sum_{s'} P(s'|s, a) (|R(s, a, s')| + \gamma |V^*(s')|)$$

حال اگر فرض کنیم $V_{max} = \max_s |V^*(s)|$ بیشینه ارزش در تمام استیت‌ها باشد:

$$V_{max} \leq R_{max} + \gamma V_{max}$$

با ساده‌سازی این نابرابری برای V_{max} :

$$V_{max}(1 - \gamma) \leq R_{max}$$

$$V_{max} \leq \frac{R_{max}}{1 - \gamma}$$

بنابراین، تابع ارزش بهینه همواره در بازه‌ی $[-\frac{R_{max}}{1-\gamma}, \frac{R_{max}}{1-\gamma}]$ کران‌دار است. (اگر $\gamma = 1$ باشد و افق زمانی بی‌نهایت باشد، این کران برقرار نیست و ممکن است تابع ارزش به سمت بی‌نهایت میل کند.)

۳. (۵۰ نمره) فرض کنید یک ربات روی مسیری افقی و در خانه‌های شماره‌گذاری شده از ۰ تا N می‌تواند حرکت کند، به گونه‌ای که:

- در هر خانه‌ی $s \leq N - 1$ ، می‌تواند با انتخاب اکشن go و با احتمال ۱، به خانه‌ی $s + 1$ برود.
- در هر خانه‌ی $s \leq N - 2$ ، می‌تواند با انتخاب اکشن jump و با احتمال $\frac{1}{4}$ به خانه‌ی شماره‌ی $s + 2$ برود و یا با احتمال $\frac{1}{4}$ در جای خود باقی بماند.
- در خانه‌ی N تنها اکشن مجاز exit است و فرایند به پایان می‌رسد.

همچنین ربات تنها در صورتی که از یک خانه‌ی s به خانه‌ی s' برود، پاداشی برابر با $(s - s')^2$ از محیط دریافت می‌نماید. در غیر این صورت پاداشی دریافت نمی‌کند. با فرض آنکه ضریب تخفیف در این مسئله برابر با $\gamma = \frac{1}{4}$ است، به سوالات زیر پاسخ دهید.

- (آ) این مسئله را در قالب یک MDP بیان نمایید.
- (ب) چند تابع سیاست منحصر به فرد برای این مسئله وجود دارد؟
- (ج) فرمول $V^*(s)$ را برای دو حالت $s = N - 1$ و $s < N - 1$ با توجه به معادلات بهینگی بلمن بنویسید.
- (د) حال $N = 3$ را در نظر بگیرید (خانه‌های ۰، ۱، ۲، ۳). الگوریتم Policy Iteration را با سیاست اولیه‌ی $\pi(s) = \text{go}$ برای همه‌ی خانه‌های دارای انتخاب، اجرا کنید تا به سیاست بهینه همگرا شود. در نهایت سیاست بهینه برای خانه‌های ۰ و ۱ چیست؟ (دقت نمایید که برای خانه‌ی آخر، همواره مقدار ارزش به ازای هر سیاست و در هر گام k یعنی $V_k^\pi(3)$ برابر با ۰ است.)

حل.

(آ) یک MDP با پنج‌تایی (S, A, P, R, γ) تعریف می‌شود:

- فضای حالت‌ها:

$$S = \{0, 1, 2, \dots, N\},$$

که خانه‌ی N حالت پایانی (terminal) است.

- فضای اکشن‌ها:

$$A(s) = \begin{cases} \{\text{go}, \text{jump}\}, & 0 \leq s \leq N - 2, \\ \{\text{go}\}, & s = N - 1, \\ \{\text{exit}\}, & s = N. \end{cases}$$

- تابع گذار (Transition):

$$P(s + 1 | s, \text{go}) = 1, \quad 0 \leq s \leq N - 1,$$

$$P(s + 2 | s, \text{jump}) = \frac{1}{4}, \quad P(s | s, \text{jump}) = \frac{1}{4}, \quad 0 \leq s \leq N - 2.$$

- تابع پاداش:

$$R(s, \text{go}, s + 1) = 1, \quad R(s, \text{jump}, s + 2) = 4, \quad R(s, \text{jump}, s) = 0.$$

- ضریب تخفیف: $\gamma = \frac{1}{4}$.

(ب) تنها خانه‌های $0, 1, \dots, N - 2$ (یعنی $N - 1$ خانه) امکان انتخاب بین دو اکشن دارند. پس تعداد سیاست‌های قطعی منحصر به فرد برابر است با:

$$2^{N-1}$$

(ج) معادلات بهینگی بلمن:

$$\begin{aligned} Q^*(s, \text{go}) &= 1 + \gamma V^*(s+1), \\ Q^*(s, \text{jump}) &= 2 + \frac{\gamma}{4} V^*(s+2) + \frac{\gamma}{4} V^*(s). \end{aligned}$$

حالت $s = N-1$ تنها go مجاز و $V^*(N) = 0$:

$$V^*(N-1) = 1 + \gamma V^*(N) = 1.$$

حالت $s < N-1$:

$$V^*(s) = \max \left\{ \underbrace{1 + \gamma V^*(s+1)}_{\text{go}}, \underbrace{2 + \frac{\gamma}{4} V^*(s+2) + \frac{\gamma}{4} V^*(s)}_{\text{jump}} \right\}.$$

با جایگذاری $\gamma = \frac{1}{4}$:

$$V^*(s) = \max \left\{ 1 + \frac{1}{4} V^*(s+1), 2 + \frac{1}{4} V^*(s+2) + \frac{1}{4} V^*(s) \right\}.$$

(د) اجرای Policy Iteration برای $N=3$:

خانه‌های دارای انتخاب: 0 و 1؛ خانه‌ی 2 اجباراً go؛ و $V(3) = 0$.

سیاست اولیه: $\pi_*(0) = \pi_*(1) = \text{go}$.

گام ۱:

ارزیابی سیاست: بعد از همگرایی، مقدار ارزش‌ها برابر است با:

$$\begin{aligned} V^{\pi_*}(3) &= 0, & V^{\pi_*}(2) &= 1, \\ V^{\pi_*}(1) &= \frac{3}{4}, & V^{\pi_*}(0) &= 1 = \frac{4}{4}. \end{aligned}$$

بهبود سیاست:

$$\begin{aligned} Q(1, \text{go}) &= 1/5, & Q(1, \text{jump}) &= 2 + \frac{1}{4} \left(\frac{3}{4} \right) = 2/375, \\ Q(0, \text{go}) &= 1/75, & Q(0, \text{jump}) &= 2 + \frac{1}{4} (1) + \frac{1}{4} \left(\frac{4}{4} \right) = 2/6875. \end{aligned}$$

در هر دو خانه jump برنده است:

$$\pi_1(0) = \text{jump}, \quad \pi_1(1) = \text{jump}.$$

گام ۲:

ارزیابی سیاست: بعد از همگرایی، مقدار ارزش‌ها برابر است با:

$$\begin{aligned} V(3) &= 0, & V(2) &= 1, \\ V(1) &= \frac{8}{3}, & V(0) &= 3. \end{aligned}$$

بهبود سیاست:

$$\begin{aligned} Q(1, \text{go}) &= 1/5, & Q(1, \text{jump}) &= 2 + \frac{1}{4} \left(\frac{8}{3} \right) = \frac{8}{3} \approx 2/667, \\ Q(0, \text{go}) &= 1 + \frac{1}{4} \left(\frac{8}{3} \right) = \frac{8}{3} \approx 2/333, & Q(0, \text{jump}) &= 2 + \frac{1}{4} (1) + \frac{1}{4} (3) = 3. \end{aligned}$$

سیاست تغییری نمی‌کند، پس همگرا شده است.

نتیجه (سیاست بهینه):

$$\pi^*(0) = \text{jump}, \quad \pi^*(1) = \text{jump}$$

با مقادیر بهینه:

$$V^*(0) = 3, \quad V^*(1) = \frac{8}{3}, \quad V^*(2) = 1, \quad V^*(3) = 0.$$