



آن نخل ناخلف که تبر شد، ز ما نبود
ما را زمانه گر شکند، ساز می‌شویم
«صائب تبریزی»

۱. (۳۰ نمره) درست یا غلط بودن گزاره‌های زیر را با ذکر دلیل کامل مشخص نمایید.

- (آ) اگر یک MDP دارای $|S|$ استیت و $|A|$ اکشن منحصر به فرد باشد، در هر Value Iteration از الگوریتم Value Iteration، پیچیدگی محاسباتی در حدود $O(|A|^2|S|)$ می‌باشد.
- (ب) اگر یک MDP دارای $|S|$ استیت و $|A|$ اکشن منحصر به فرد باشد، آنگاه حداکثر تعداد گام‌های بهبود سیاست در الگوریتم Policy Iteration برابر با $|S|^{|A|}$ می‌باشد.
- (ج) اگر به همه پاداش‌های یک MDP یک ثابت مثبت c را اضافه کنیم، تابع ارزش بهینه V^* ممکن است تغییر کند اما سیاست بهینه π^* بدون تغییر باقی می‌ماند.
۲. (۲۰ نمره) در یک MDP می‌دانیم که مقادیر پاداش‌ها همواره در بازه $[a, b]$ قرار دارند. آیا مقدار ارزش بهینه برای تمام استیت‌ها (یعنی $V^*(s)$) نیز لزوماً کران‌دار است؟ اگر پاسخ شما مثبت است، کران $V^*(s)$ را مشخص نمایید و در غیر این صورت، دلیل خود را مطرح کنید.
۳. (۵۰ نمره) فرض کنید یک ربات روی مسیری افقی و در خانه‌های شماره‌گذاری شده از ۰ تا N می‌تواند حرکت کند، به گونه‌ای که:

- در هر خانه‌ای $s \leq N - 1$ ، می‌تواند با انتخاب اکشن go و با احتمال ۱، به خانه‌ای $s + 1$ برود.
- در هر خانه‌ای $s \leq N - 2$ ، می‌تواند با انتخاب اکشن jump و با احتمال $\frac{1}{2}$ به خانه‌ای شماره‌ی $s + 2$ برود و یا با احتمال $\frac{1}{2}$ در جای خود باقی بماند.
- در خانه‌ی N تنها اکشن مجاز exit است و فرایند به پایان می‌رسد.

همچنین ربات تنها در صورتی که از یک خانه‌ی s به خانه‌ی s' برود، پاداشی برابر با $(s - s')^2$ از محیط دریافت می‌نماید. در غیر این صورت پاداشی دریافت نمی‌کند. با فرض آنکه ضریب تخفیف در این مسئله برابر با $\gamma = \frac{1}{2}$ است، به سوالات زیر پاسخ دهید.

- (آ) این مسئله را در قالب یک MDP بیان نمایید.
- (ب) چند تابع سیاست منحصر به فرد برای این مسئله وجود دارد؟
- (ج) فرمول $V^*(s)$ را برای دو حالت $s = N - 1$ و $s < N - 1$ با توجه به معادلات بهینگی بلمن بنویسید.
- (د) حال $N = 3$ را در نظر بگیرید (خانه‌های ۰، ۱، ۲، ۳). الگوریتم Policy Iteration را با سیاست اولیه‌ی $\pi_0(s) = \text{go}$ برای همه‌ی خانه‌های دارای انتخاب، اجرا کنید تا به سیاست بهینه همگرا شود. در نهایت سیاست بهینه برای خانه‌های ۰ و ۱ چیست؟ (دقت نمایید که برای خانه‌ی آخر، همواره مقدار ارزش به ازای هر سیاست و در هر گام k یعنی $V_k^\pi(3)$ برابر با ۰ است.)